Méthode de Monte Carlo

Rapport de l'exercice "Autour du Put"

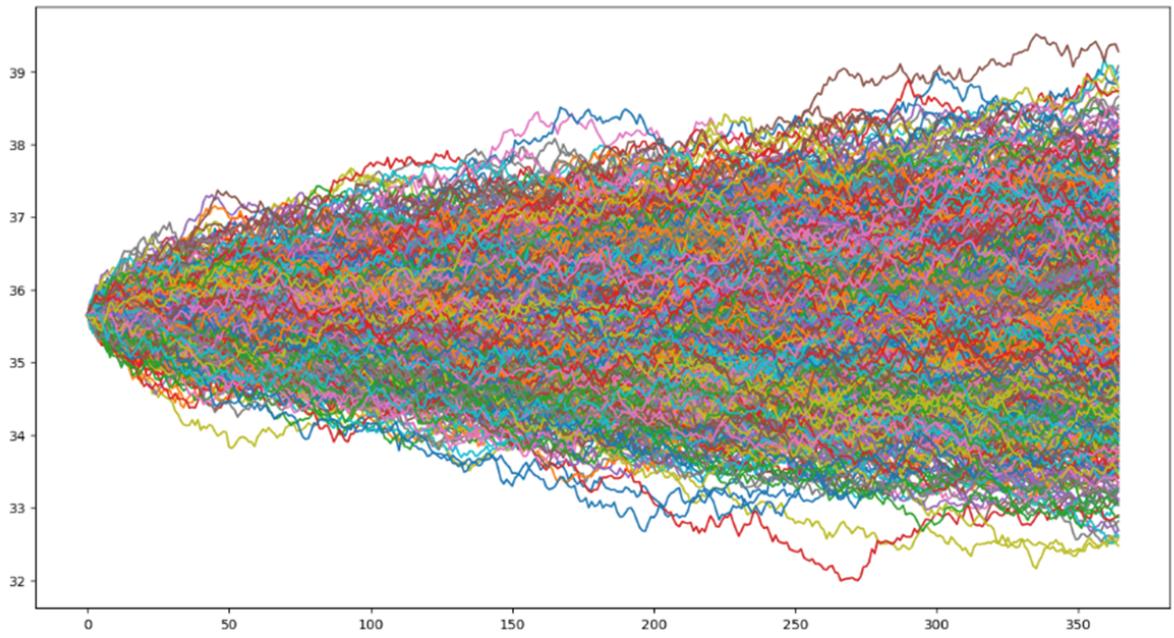

just-nice-guy - mon camarade
Février 2026

M2 MFCA - Université de Lille

Table des matières

1 Exercice 1 : Densité implicite **2**
1.1 Distribution implicite 2
1.2 Prix du put 4
1.3 Bonus : Fonction de répartition 9

2 Exercice 2 : ajout d'une barière continue **12**
2.1 Pricing 12
2.2 Réduction de variance 14
2.3 Sensibilité aux paramètres 16

3 Exercice 3 : Plusieurs sous-jacents **17**
3.1 Pricing 18
3.2 Réduction de variance 20
3.3 Bonus : Réduction de variance par la méthode de Kemna–Vorst 23

4 Exercice 4 : Computing Greeks **27**
4.1 Méthode numérique 28
4.2 Comparaison 32
4.3 Variation 33
4.4 Réduction de variance : Importance sampling 35

5 Exercice 5 : volatilité stochastique et sauts **37**
5.1 Diffusion du sous-jacent 37
5.2 Pricing de Put 39
5.3 Variations et significativités 41
5.4 Réduction du biais 43

Les résultats importants ou finaux seront encadrés en vert et les boîtes couleur turquoise décrivent les consignes comme elles figurent dans le document. Les boîtes blanc cassé sont juste la pour résumé notre avancement dans la question et expliquer ce que l'on va faire par la suite dans les questions plus longues.

1 Exercice 1 : Densité implicite

Écrivons le prix du Put dans le modèle de Black Scholes.

$$Put_{BS}(S_t, K, r, \sigma, T) = \mathbb{E}\left[e^{-r(T-t)}(K - S_T)_+ | \mathcal{F}_t\right]$$

$$S_T = S_t e^{(r-\frac{\sigma^2}{2})(T-t)+\sigma(W_T-W_t)}$$

1.1 Distribution implicite

En supposant les hypothèses du modèle de Black Scholes, évaluez la fonction de répartition et la densité du sous jacent en T.

Objectif 1

Approcher la loi de manière empirique (distribution et fonction de répartition) via la méthode de Monte Carlo

L'objectif de cette première question est d'approcher la loi du sous-jacent avec la méthode de Monte-Carlo. Pour cela on va simuler des dizaines de milliers de trajectoires afin d'approcher la distribution et pour la fonction de répartition. Cela est fait dans le code.

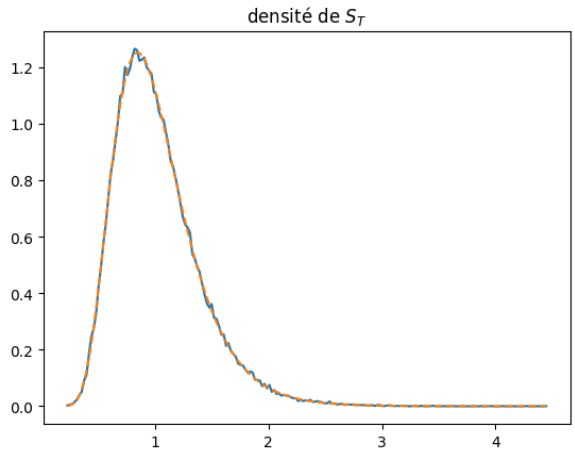

FIGURE 1 – Approche empirique VS formule fermée - densité de S_T

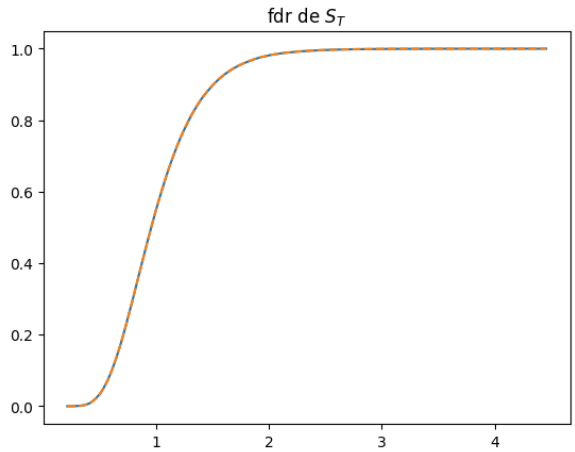

FIGURE 2 – Approche empirique VS formule fermée - Fonction de répartition de S_T

Voir le code 1.1

Objectif 2

Essayer de trouver une formule fermée et valider votre approche empirique.

Pour trouver la formule fermée, on commence par appliquer un logarithme à la formule donnée. On peut appliquer le logarithme car dans notre cas, S_T est toujours positif.

$$\ln(S_T) = \ln(S_t) + \left(r - \frac{\sigma^2}{2}\right)(T-t) + \sigma(W_T - W_t)$$

Or $(W_t)_{t\in\mathbb{R}}$ est un mouvement brownien. On utilise le fait que :

$$W_T - W_t \sim \mathcal{N}(0, (T-t))$$

et donc,

$$\sigma(W_T - W_t) \sim \mathcal{N}(0, \sigma^2(T-t))$$

On a donc le résultat suivant :

$$ln(S_T) \sim \mathcal{N}(\mu, \Sigma^2) \qquad \text{avec} \qquad \begin{cases} \mu = \ln(S_t) + \left(r - \frac{\sigma^2}{2}\right)(T-t) \\ \Sigma^2 = \sigma^2(T-t) \end{cases}$$

Et on a donc la fonction de densité de $\ln(S_T)$ qui est celle d'une gaussienne, et qui s'exprime donc :

$$\forall x \in \mathbb{R}, f_{\ln(S_T)}(x) = \frac{1}{\sqrt{2\pi}\Sigma} e^{-\frac{(x-\mu)^2}{2\Sigma^2}}$$

Une fois que l'on à trouvé la fonction de densité de $ln(S_T)$ on va pouvoir, grâce à elle, trouver la fonction de densité de S_T grâce au théorème de transfert.

On pose $X = \ln(S_T)$ une variable aléatoire suivant donc une loi normale $\mathcal{N}(\mu, \Sigma^2)$

Pour toute fonction de test h mesurable et bornée, on cherche à exprimer $E[h(S_T)]$. Puisque $S_T = e^X$, on a :

$$E[h(S_T)] = E[h(e^X)] = \int_{-\infty}^{+\infty} h(e^x) f_X(x)\, dx$$

Effectuons le changement de variable $s = e^x$. On a alors :

- $x = \ln(s)$
- $dx = \frac{1}{s} ds$
- Lorsque $x \to -\infty$, $s \to 0$
- Lorsque $x \to +\infty$, $s \to +\infty$

On obtient :

$$E[h(S_T)] = \int_0^{+\infty} h(s) \cdot f_X(\ln(s)) \cdot \frac{1}{s}\, ds$$

En remplaçant $f_X = f_{\ln(S_T)}$ par son expression de fonction de densité d'une loi normale :

$$E[h(S_T)] = \int_0^{+\infty} h(s) \cdot \left[\frac{1}{s\Sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln(s)-\mu)^2}{2\Sigma^2} \right) \right] ds$$

Or cela est vrai pour toute fonction h mesurable bornée bien définie. Donc, par le théorème de la fonction muette, on identifie le terme entre crochets comme étant la densité de S_T (notée f_{S_T}). Ainsi, pour tout $s > 0$:

$$\boxed{f_{S_T}(s) = \frac{1}{s\Sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln(s)-\mu)^2}{2\Sigma^2} \right)}$$

Et $f_{S_T}(s) = 0$ pour $s \leq 0$.

Cette loi est une loi dite lognormale.

On calcule maintenant la fonction de répartition en repartant de la fonction de densité de $\ln(S_T)$

On calcule la fonction de répartition (dans le calcul qui vient, on peut passer au logarithme car S_T est positif et donc x aussi) :

$$\begin{aligned}
\forall x \in \mathbb{R}, \quad F_{S_T|\mathcal{F}_t}(x) &= \mathbb{P}(S_T \leq x|\mathcal{F}_t) \\
&= \mathbb{P}(\ln(S_T) \leq \ln(x)|\mathcal{F}_t) \\
&\text{On utilise le théorème de transfert} \\
&= \int_{-\infty}^{\ln(x)} \frac{1}{\sqrt{2\pi}\Sigma} e^{-\frac{(t-\mu)^2}{2\Sigma^2}} dt \qquad (*) \\
&\text{On standardise en posant } z = \frac{t-\mu}{\Sigma},\ dt = \Sigma dz \\
&= \int_{-\infty}^{\frac{\ln x - \mu}{\Sigma}} \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} dz \\
&= \boxed{\Phi\left(\frac{\ln x - \mu}{\Sigma} \right)}
\end{aligned}$$

Dans cette formule, Φ est la fonction de répartition de la loi normale standard, donnée explicitement par

$$\Phi(y) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{y} e^{-\frac{t^2}{2}} dt.$$

On vérifie bien que c'est une fonction de densité en faisant le changement de variable $x = e^u$ qui montre que la fonction s'intègre bien à 1

1.2 Prix du put

Objectif 1 : Formule fermée

Sous les hypothèse du modèle de Black Scholes, démontrez la formule fermée du Put européen.

On part de la formule du Put Européen donnés dans l'énoncé.

$$\begin{aligned} Put_{BS}(S_t, K, r, \sigma, T) &= \mathbb{E}\left[e^{-r(T-t)}(K - S_T)_+ | \mathcal{F}_t\right] \\ &= e^{-r(T-t)}\mathbb{E}\left[(K - S_T)_+ | \mathcal{F}_t\right] \\ &\quad \text{Car } e^{-r(T-t)} \text{ est indépendante par rapport à la filtration } \mathcal{F}_t \end{aligned}$$

Or, si on exprime la quantité dans l'espérance avec une disjonction de cas,

$$(K - S_T)_+ = \begin{cases} K - S_T & \text{Si} \quad S_T \leq K \\ 0 & \text{sinon} \end{cases}$$

Alors on peut l'exprimer de manière plus directe avec des indicatrices :

$$\begin{aligned} e^{-r(T-t)}\mathbb{E}\left[(K - S_T)_+ | \mathcal{F}_t\right] &= e^{-r(T-t)}\Big(\mathbb{E}\left[K \cdot \mathbb{1}_{S_T \leq K} | \mathcal{F}_t\right] - \mathbb{E}\left[S_T \cdot \mathbb{1}_{S_T \leq K} | \mathcal{F}_t\right]\Big) \\ &= e^{-r(T-t)}\Big(K \cdot \mathbb{P}(S_T \leq K | \mathcal{F}_t) - \mathbb{E}\left[S_T \cdot \mathbb{1}_{S_T \leq K} | \mathcal{F}_t\right]\Big) \end{aligned}$$

On va calculer séparement les deux partie de notre formule. On va d'abord réécrire l'inégalité de gauche $S_T \leq K$, puis on va calculer le membre de droite $\mathbb{E}\left[S_T \cdot \mathbb{1}_{S_T \leq K} | \mathcal{F}_t\right]$.

Pour l'inégalité de gauche, on va réécrire l'inégalité $S_T \leq K$ de cette manière :

$$\begin{aligned} S_T &= S_t e^{(r - \frac{\sigma^2}{2})(T-t) + \sigma(W_T - W_t)} \\ &= S_t e^{(r - \frac{\sigma^2}{2})(T-t) + \sigma\sqrt{T-t}Z} \\ &\text{avec} \quad Z \sim \mathcal{N}(0, 1) \end{aligned}$$

Donc, de la même manière que pour le 1.1,

$$\ln(S_T) = \ln(S_t) + \left(r - \frac{\sigma^2}{2}\right)(T - t) + \sigma\sqrt{T - t} \cdot Z$$

On va alors utiliser cette formule dans l'inégalité de la manière suivante :

$$\begin{aligned} S_T \leq K &\Leftrightarrow \ln(S_T) \leq \ln K \\ &\Leftrightarrow \ln(S_t) + \left(r - \frac{\sigma^2}{2}\right)(T - t) + \sigma\sqrt{T - t} \cdot Z \leq \ln K \\ &\Leftrightarrow \sigma\sqrt{T - t} \cdot Z \leq \ln(K) - \ln(S_t) - \left(r - \frac{\sigma^2}{2}\right)(T - t) \\ &\Leftrightarrow Z \leq \frac{1}{\sigma\sqrt{T - t}} \cdot \left(\ln(K) - \ln(S_t) - \left(r - \frac{\sigma^2}{2}\right)(T - t)\right) \\ &\Leftrightarrow Z \leq Z_K \end{aligned}$$

En posant la constante Z_K :

$$Z_K = \frac{1}{\sigma\sqrt{T - t}} \cdot \left(\ln(K) - \ln(S_t) - \left(r - \frac{\sigma^2}{2}\right)(T - t)\right)$$

On a donc que

$$\mathbb{P}(S_T \leq K | \mathcal{F}_t) = \mathbb{P}(Z \leq Z_K | \mathcal{F}_t) = \boxed{\Phi(Z_K)}$$

Avec Φ la fonction de répartition de la loi normale centrée réduite. On note de même ϕ sa fonction de densité.

Pour la formule de droite, calculons $\mathbb{E}\left[S_T \cdot \mathbb{1}_{S_T \leq K} | \mathcal{F}_t\right]$:

$$\begin{aligned}
\mathbb{E}\left[S_T \cdot \mathbb{1}_{S_T \leq K} | \mathcal{F}_t\right] &= \mathbb{E}\left[S_T \cdot \mathbb{1}_{Z \leq Z_K} | \mathcal{F}_t\right] \\
&= S_t e^{(r - \frac{\sigma^2}{2})(T-t)} \mathbb{E}\left[e^{\sigma\sqrt{T-t} \cdot Z} \cdot \mathbb{1}_{Z \leq Z_K} | \mathcal{F}_t\right] \\
&\quad \text{Car } S_t e^{(r - \frac{\sigma^2}{2})(T-t)} \text{ est indépendante par rapport à la filtration } \mathcal{F}_t
\end{aligned}$$

On calcul alors cette espérance conditionnelle :

$$\begin{aligned}
\mathbb{E}\left[e^{\sigma\sqrt{T-t} \cdot Z} \cdot \mathbb{1}_{Z \leq Z_K} | \mathcal{F}_t\right] &= \int_{-\infty}^{+\infty} e^{\sigma\sqrt{T-t} \cdot z} \cdot \mathbb{1}_{Z \leq Z_K} \cdot \phi(z)\ dz \\
&= \int_{-\infty}^{Z_K} e^{\sigma\sqrt{T-t} \cdot z} \phi(z)\ dz \\
&= \int_{-\infty}^{Z_K} e^{\sigma\sqrt{T-t} \cdot z} \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}\ dz \\
&= \int_{-\infty}^{Z_K} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(z - \sigma\sqrt{T-t})^2 + \frac{1}{2}\sigma^2(T-t)}\ dz \\
&= e^{\frac{1}{2}\sigma^2(T-t)} \int_{-\infty}^{Z_K} \phi(z - \sigma\sqrt{T-t})\ dz \\
&\underset{u = z - \sigma\sqrt{T-t}}{=} e^{\frac{1}{2}\sigma^2(T-t)} \int_{-\infty}^{Z_K - \sigma\sqrt{T-t}} \phi(u) du \\
&= e^{\frac{1}{2}\sigma^2(T-t)} \Phi(Z_K - \sigma\sqrt{T-t})
\end{aligned}$$

Donc, en reprennant le calcul où l'on en était :

$$\begin{aligned}
\mathbb{E}\left[S_T \cdot \mathbb{1}_{S_T \leq K} | \mathcal{F}_t\right] &= S_t e^{(r - \frac{\sigma^2}{2})(T-t)} e^{\frac{1}{2}\sigma^2(T-t)} \Phi(Z_K - \sigma\sqrt{T-t}) \\
&= \boxed{S_t e^{r(T-t)} \Phi(Z_K - \sigma\sqrt{T-t})}
\end{aligned}$$

Enfin, en joignant les deux morceaux de la formule que l'on calcul :

$$\begin{aligned}
Put_{BS}(S_t, K, r, \sigma, T) &= e^{-r(T-t)} \Big(K \cdot \Phi(-d_2) - S_t e^{r(T-t)} \cdot \Phi(-d_1)\Big) \\
&= \boxed{K e^{-r(T-t)} \Phi(-d_2) - S_t \Phi(-d_1)}
\end{aligned}$$

avec :

$$\begin{cases}
-d_1 = Z_K - \sigma\sqrt{T-t} = -\frac{\ln(\frac{S_t}{K}) + (r + \frac{\sigma^2}{2})(T-t)}{\sigma\sqrt{T-t}} \\
-d_2 = Z_K = -d_1 + \sigma\sqrt{T-t}
\end{cases}$$

D'où la formule finale du prix du Put européen dans la formule de Black-Schole.

Objectif 2 : Théorème de transfert

Évaluez l'espérance conditionnelle à partir de la fonction de répartition (numérique ou exacte) du sous-jacent en T.

$$\mathbb{E}\left[e^{-r(T-t)}(K-S_T)_+|\mathcal{F}_t\right] = \int_0^\infty e^{-r(T-t)}(K-s)_+ \, \mathbb{P}_{S_T|\mathcal{F}_t}(ds)$$

Justifions d'abord la formule de l'énoncé. On considère le prix d'un Put européen sous le modèle de Black-Scholes comme donné dans l'énoncé :

$$Put_{BS}(S_t, K, r, \sigma, T) = \mathbb{E}\left[e^{-r(T-t)}(K-S_T)_+ \mid \mathcal{F}_t\right].$$

On pose la fonction $f(s) = e^{-r(T-t)}(K-s)_+$.
Par définition de l'espérance conditionnelle et du théorème de transfert, on a :

$$\mathbb{E}\left[f(S_T) \mid \mathcal{F}_t\right] = \int_{\mathbb{R}_+} f(s) \, \mathbb{P}_{S_T|\mathcal{F}_t}(ds).$$

Ainsi, on retrouve la formule de la question :

$$\mathbb{E}\left[e^{-r(T-t)}(K-S_T)_+ \mid \mathcal{F}_t\right] = \int_0^\infty e^{-r(T-t)}(K-s)_+ \, \mathbb{P}_{S_T|\mathcal{F}_t}(ds).$$

Une fois la formule de l'énoncé justifiée, on va exprimer plus simplement l'intégrale trouvée afin de pouvoir la simuler par la suite.

On cherche d'abord à exprimer $\mathbb{P}_{S_T|\mathcal{F}_t}$. On a que S_T suit une loi lognormale conditionnelle à $\mathcal{F}_t$ car, on rappelle que :

$$S_T = S_t \exp\left((r - \tfrac{\sigma^2}{2})(T-t) + \sigma(W_T - W_t)\right).$$

Et que donc, en reprenant les calculs fait en 1.1 (Objectif 2), on a que la densité de S_T est :

$$f_{S_T|\mathcal{F}_t}(s) = \frac{1}{s\sigma\sqrt{2\pi(T-t)}} \exp\left(-\frac{\left(\ln(s/S_t) - (r - \frac{\sigma^2}{2})(T-t)\right)^2}{2\sigma^2(T-t)}\right), \quad s > 0.$$

En remplaçant et en simplifiant le $(K-S_T)_+$ prix du Put devient :

$$Put_{BS}(S_t, K, r, \sigma, T) = e^{-r(T-t)} \int_0^K (K-s) \, f_{S_T|\mathcal{F}_t} \, ds.$$

Pour simplifier cette intégrale, on pose $F_{S_T|\mathcal{F}_t}(s) = \mathbb{P}(S_T \leq s \mid \mathcal{F}_t)$ la fonction de répartition du sous-jacent en T. Par intégration par parties, on pose :

$$u = K - s \implies du = -ds$$
$$dv = f_{S_T|\mathcal{F}_t}(s)ds \implies v = F_{S_T|\mathcal{F}_t}(s)$$

La formule de l'IPP est : $\int u \, dv = [uv] - \int v \, du$ et donne alors :

$$\begin{aligned}\int_0^K (K-s)\, f_{S_T|\mathcal{F}_t}\, ds &= \Big[(K-s)F_{S_T|\mathcal{F}_t}(s)\Big]_0^K - \int_0^K F_{S_T|\mathcal{F}_t}(s)\,(-ds) \\ &= \Big[(K-s)F_{S_T|\mathcal{F}_t}(s)\Big]_0^K + \int_0^K F_{S_T|\mathcal{F}_t}(s)\, ds.\end{aligned}$$

Comme $F(0) = 0$ et $F(K) = \mathbb{P}(S_T \leq K)$, le crochet s'annule et on obtient :

$$\int_0^K (K-s)\, f_{S_T|\mathcal{F}_t}\, ds = \int_0^K F_{S_T|\mathcal{F}_t}(s)\, ds$$

Donc en reprenant le facteur devant :

$$Put_{BS}(S_t, K, r, \sigma, T) = \boxed{e^{-r(T-t)} \int_0^K F_{S_T|\mathcal{F}_t}(s)\, ds}$$

Cette intégrale est calculée analytiquement pour obtenir une estimation de l'espérance conditionnelle dans le code joint.

Voir le code 1.2

Objectif 3 : Fonction de répartition inverse

Connaissant la fonction de répartition du sous-jacent, évaluez l'espérance conditionnelle en simulant à partir de la fonction de répartition inverse du sous-jacent en T.

$$\mathbb{E}\left[e^{-r(T-t)}(K - S_T)_+ | \mathcal{F}_t\right] \approx \frac{1}{M} \sum_{i=1}^{M} e^{-r(T-t)}(K - \mathcal{F}_{S_T}^{-\infty}(U^i))_+$$

On reprend formule du Put de l'énoncé :

$$Put_{BS}(S_t, K, r, \sigma, T) = \mathbb{E}\left[e^{-r(T-t)}(K - S_T)+ \mid \mathcal{F}_t\right],$$

Comme montré précédement, la loi de S_T est lognormale. Sa fonction de répartition, $F(s)$, a été calculée précédemment et par la méthode d'inversion, ce qui nous permet de simuler S_T à partir d'une variable uniforme $U \sim \mathcal{U}(0,1)$ selon la formule :

$$S_T = F^{-1}(U).$$

Avec

$$F^{-1}(u) = \inf\{s : F(s) \geq u\}.$$

Sous Black-Scholes, S_T suit une loi lognormale, donc :

$$F^{-1}(u) = \exp\big(\mu + \Sigma\Phi^{-1}(u)\big),$$

où :

$$\mu = \ln(S_t) + (r - \tfrac{\sigma^2}{2})(T-t), \quad \Sigma = \sigma\sqrt{T-t},$$

et Φ^{-1} est la fonction quantile de la loi normale standard.

En utilisant la méthode de Monte Carlo, on effectue M tirages indépendants $U^i \sim \mathcal{U}(0,1)$, on obtient l'approximation :

$$\mathbb{E}\left[e^{-r(T-t)}(K-S_T)_+ \mid \mathcal{F}_t\right] \approx \frac{1}{M}\sum_{i=1}^{M} e^{-r(T-t)}\big(K-F^{-1}(U^i)\big)_+.$$

On implémente cette méthode et calculons les résultats dans le code en annexe.

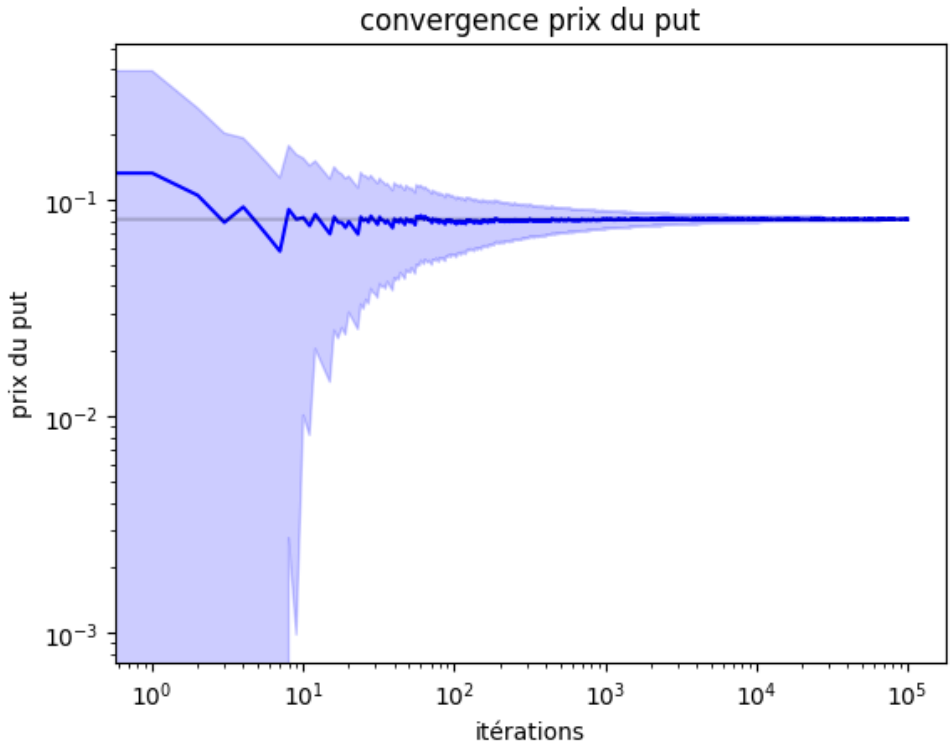

FIGURE 3 – Prix du Put par Monte Carlo (Fonction de répartition inverse) - Résultats numériques : esperance = 0.08125, std = 0.12530, err. mult. = -7.0262

Voir le code en 1.2

1.3 Bonus : Fonction de répartition

Objectif

Trouver l'expression de la distribution implicite du sous-jacent en T pour une volatilité implicite dépendent du temps et de l'espace ($\sigma(t,s)$).

Dans ce bonus, r est constant et la volatilité dépend du temps et de l'espace. La dynamique du sous-jacent est maintenant de la forme :

$$dS_t = rS_t\,dt + \sigma(t,S_t)S_t\,dW_t, \quad S_0 > 0$$

Contrairement au modèle de Black-Scholes standard (avec σ constant), cette dynamique n'admet pas de solution explicite générale pour S_T.

Dans cette section, nous allons aboutir à l'équation de Fokker-Plank pour la diffusion, appliquée aux fonctions r (constante) et $\sigma(t,s)$. Pour y arriver, on doit faire des hypothèses sur σ qui sont les suivantes :

— $\sigma(t,s)$ est continue en (t,s) et localement lipschitzienne en s,

— $\sigma(t,s)$ est à croissance au plus linéaire en s,

Ces hypothèses garantissent l'existence, l'unicité et la positivité presque sûre de la solution S_t. En particulier, le processus ne touche pas la frontière $s=0$ (car $S_0>0$) et admet des moments finis sur tout horizon fini.

On note $f_{S_T}(t,s)$ la fonction de densité de S_T à caractériser.

$\forall f \in \mathcal{C}^2(\mathbb{R}_+)$, on considère $f(S_t)$ et par la formule d'Itô, on a :

$$df(S_t) = f'(S_t)dS_t + \frac{1}{2}f''(S_t)d\langle S\rangle_t$$

Or :

$$\begin{aligned} dS_t &= rS_t\,dt + \sigma(t,S_t)S_t\,dW_t, \\ d\langle S\rangle_t &= \big(\sigma(t,S_t)S_t\big)^2 dt = \sigma^2(t,S_t)S_t^2\,dt, \end{aligned}$$

Donc on a le résultat :

$$\begin{aligned} df(S_t) &= f'(S_t)\,dS_t + \tfrac{1}{2}f''(S_t)\,d\langle S\rangle_t \\ &= \big(rS_tf'(S_t) + \tfrac{1}{2}\sigma^2(t,S_t)S_t^2f''(S_t)\big)\,dt + \sigma(t,S_t)S_tf'(S_t)\,dW_t. \end{aligned}$$

Maintenant, on va exprimer de deux manière différentes la quantité $\frac{d}{dt}\mathbb{E}[f(S_t)]$, puis égaliser les deux et en déduire l'équation finale.

Première méthode, On prend l'espérance du résultat précédent (ce qui laisse uniquement le terme en dt car le brownien est d'esperance nulle)

$$\begin{aligned} \frac{d}{dt}\mathbb{E}[f(S_t)] &= \mathbb{E}[rS_tf'(S_t) + \frac{1}{2}\sigma^2(t,S_t)S_t^2f''(S_t)] \\ &= \mathbb{E}[rS_tf'(S_t)] + \frac{1}{2}\mathbb{E}[\sigma^2(t,S_t)S_t^2f''(S_t))] \end{aligned}$$

Et donc en utilisant la définition de l'espérance, on a les deux intégrales suivantes :

$$\begin{aligned} \mathbb{E}[rS_tf'(S_t)] &= \int_0^{+\infty} rsf'(s)f_{S_T}(t,s)ds \\ \mathbb{E}[\sigma^2(t,S_t)S_t^2f''(S_t))] &= \int_0^{+\infty} \sigma^2(t,s)s^2f''(s)f_{S_T}(t,s)ds \end{aligned}$$

Que l'on peut calculer en réalisant sur le premier terme une IPP et sur le second deux IPP à la suite. Dans ce cas,

$$\int_0^{+\infty} rsf'(s)\, f_{S_T}(t,s)\, ds = \Big[rsf(s)f_{S_T}(t,s)\Big]_0^{+\infty} - \int_0^{+\infty} f(s)\, \partial_s\Big(rsf_{S_T}(t,s)\Big)\, ds,$$

$$\int_0^{+\infty} \sigma^2(t,s)s^2 f''(s)\, f_{S_T}(t,s)\, ds = \Big[f'(s)\sigma^2(t,s)s^2 f_{S_T}(t,s)\Big]_0^{+\infty} - \Big[f(s)\partial_s\Big(\sigma^2(t,s)s^2 f_{S_T}(t,s)\Big)\Big]_0^{+\infty} + \int_0^{+\infty} f(s)\, \partial_{ss}\Big(\sigma^2(t,s)s^2 f_{S_T}(t,s)\Big)\, ds.$$

Les crochets s'annulent car, premièrement, le processus S_t reste strictement positif, donc $p(t,0) = 0$, et les facteurs s et s^2 annulent aussi le crochet en 0. Deuxièmement, la densité décroît suffisamment vite à l'infini grâce aux moments finis supposé au début. Les crochets s'annulent donc tous.

On obtient finalement la première manière d'exprimer la quantité $\frac{d}{dt}\mathbb{E}[f(S_t)]$ par :

$$\boxed{\int_0^{+\infty} f(s)\left[-\partial_s\Big(rsf_{S_T}(t,s)\Big) + \frac{1}{2}\partial_{ss}\Big(\sigma^2(t,s)s^2 f_{S_T}(t,s)\Big)\right] ds}$$

Deuxième méthode, par définition de l'espérance,

$$\mathbb{E}[f(S_t)] = \int_0^{+\infty} f(s) f_{S_T}(t,s) ds$$

D'où, en dérivant temporellement sous le signe intégrale (possible car les intégrales sont finies, car les moments sont finis)

$$\boxed{\frac{d}{dt}\mathbb{E}[f(S_t)] = \int_0^{+\infty} f(s)\partial_t f_{S_T}(t,s) ds}$$

Et donc par identification, on a

$$\int_0^{+\infty} f(s)\partial_t f_{S_T}(t,s) ds = \int_0^{+\infty} f(s)\Big[-\partial_s\Big(rsf_{S_T}(t,s)\Big) + \frac{1}{2}\partial_{ss}\Big(\sigma^2(t,s)s^2 f_{S_T}(t,s)\Big)\Big]$$

Or cela est vrai $\forall f \in \mathcal{C}^2(\mathbb{R}_+)$, donc par identification, la fonction $f_{S_T}(t,s)$ est solution de l'équation différentielle suivante (dite équation de Fokker–Planck associée à la diffusion) :

$$\boxed{\partial_t f_{S_T}(t,s) = -\partial_s\Big(rsf_{S_T}(t,s)\Big) + \frac{1}{2}\partial_{ss}\Big(\sigma^2(t,s)s^2 f_{S_T}(t,s)\Big)}$$

Avec pour condition initiale :

$$f_{S_T}(0,s) = \delta(s - s_0)$$

En l'absence de formule fermée, on va approcher la loi de S_T par Monte Carlo. En utilisant la méthode du schéma d'Euler vue en cours, on obtient une approximation de S_T et de sa distribution empirique, permettant d'estimer la densité et la fonction de répartition

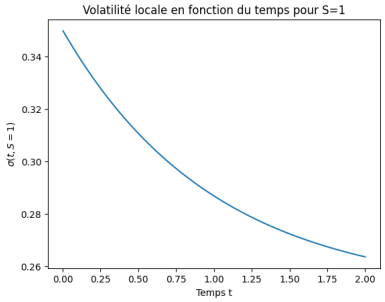

FIGURE 4 – Volatilité local en fonction du temps (S=1)

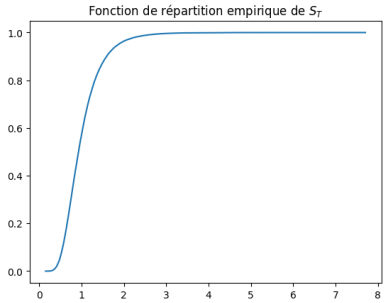

FIGURE 5 – Fonction de répartition empirique de S_T

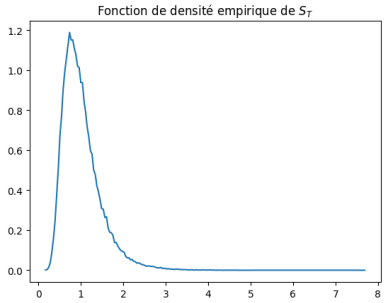

FIGURE 6 – Fonction de densité empirique de S_T

du sous-jacent.

Voir le code 1.3

Cette partie a été longue à comprendre et à raccourcir pour la rendre à peu près concise. On omet une certain quantité de théorie, qui a cependant largement aidé à la réponse de ce bonus, notement provenant du papier [1]

2 Exercice 2 : ajout d'une barière continue

L'objectif est de trouver dans le modèle de Black Scholes le prix du produit payant le payoff suivant :

$$\Pi_T = (K - S_T)_+ \mathbb{1}_{\{T<\tau^{\mathcal{D}}\}} \tag{1}$$

$$\tau^{\mathcal{D}} = \inf_{0<t}\{t, S_t \notin \mathcal{D}\} \tag{2}$$

$$\mathcal{D} = [L, \infty[\tag{3}$$

2.1 Pricing

En utilisant le schéma de discrétisation d'Euler, évaluer le prix du produit précédent :

$$\mathbb{E}[e^{-r(T-t)}\Pi_T|\mathcal{F}_t] = \mathbb{E}[e^{-r(T-t)}(K - S_T)_+ \mathbb{1}_{\{T<\tau^{\mathcal{D}}\}}|\mathcal{F}_t] \tag{4}$$

Les paramètres numériques seront les suivants : $K = 1.1$, $L = 0.7$. Vous pouvez choisir le générateur de nombre aléatoire que vous souhaitez. Néanmoins, afin de simuler des variables aléatoires normales, vous utiliserez la méthode de Box Muller.

Établir les deux résultats suivants :

Objectif : Seulement aux dates de discrétisation

Faire une simple évaluation du franchissement de la barrière aux dates de discrétisation.

D'après l'énoncé, le payoff du produit est :

$$\Pi_T = (K - S_T)^+ \mathbb{1}_{T<\tau_D}$$

avec :

$$\tau_D = \inf_{0 \leq t \leq T} \{t \mid S_t \leq L\}$$

Dans le modèle de Black-Scholes :

$$S_{t+\Delta t} = S_t \exp\left((r - \frac{\sigma^2}{2})\Delta t + \sigma\sqrt{\Delta t} Z\right)$$

où $Z \sim \mathcal{N}(0, 1)$.

Dans cette première approche, on vérifie uniquement si :

$$\min_k S_{t_k} > L$$

où t_k sont les dates de discrétisation.
Cette méthode introduit un biais positif car un franchissement entre deux dates peut ne pas être détecté. Au final, lorsque le pas de temps $\Delta t \to 0$, cet estimateur converge vers la vraie valeur.

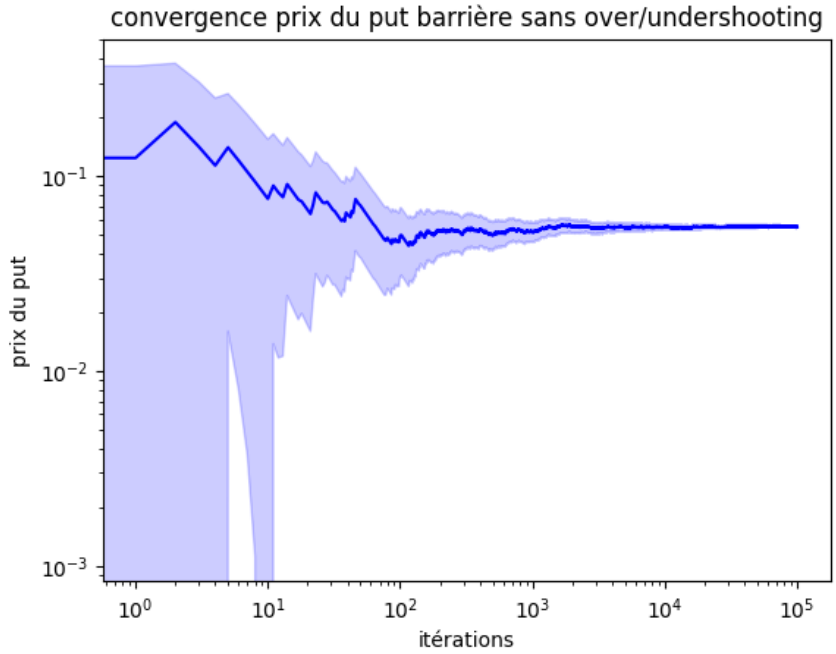

FIGURE 7 – Convergence du prix avec évalutation du franchissement de la barrière seulement au date de discrétisation - Résultats numériques : esperance = 0.05483, std = 0.09849

Objectif : Estimation de l'over/under shooting

Utiliser le pont brownien afin d'ajuster votre estimateur pour prendre en compte les probabilités d'avoir franchi ou non la barrière entre deux dates de discrétisation.

Entre deux dates de discrétisation, la trajectoire du log prix suit un pont brownien conditionnel :

$$\log S_t | (\log S_{t_i}, \log S_{t_{i+1}})$$

On peut approximer la probabilité de franchissement de la barrière entre deux dates :

$$P(\min_{t_i \leq t \leq t_{i+1}} S_t \leq L)$$

Cette correction permet de réduire fortement le biais de discrétisation. L'estimateur devient alors conditionné par la probabilité de franchissement sur chaque intervalle.

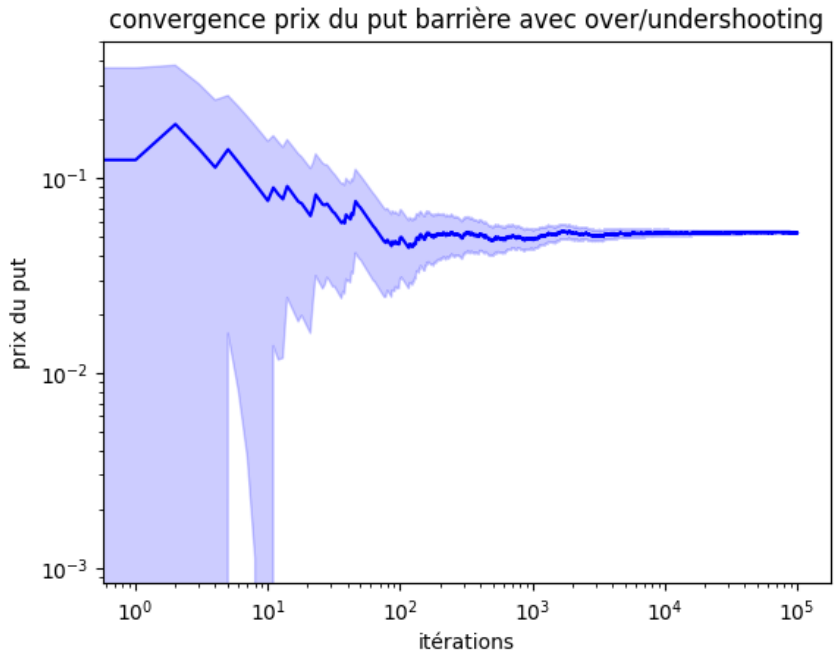

FIGURE 8 – Convergence du prix avec estimation de l'over/undershooting - Résultats numériques : esperance = 0.05230, std = 0.09495

Voir le code 2.1

2.2 Réduction de variance

Objectif 1

Utiliser le Put Européen comme variable de contrôle. Vous pouvez donner également un regard critique sur vos résultats précédents.

On utilise :

$$X = e^{-r(T-t)}(K - S_T)^+ \mathbb{1}_{T<\tau_D}$$

et comme variable de contrôle :

$$Y = e^{-r(T-t)}(K - S_T)^+$$

On construit l'estimateur :

$$X^* = X - \beta(Y - E[Y])$$

avec :

$$\beta = \frac{Cov(X,Y)}{Var(Y)}$$

Comme le put classique est fortement corrélé avec le put barrière, on va réduire la variance.

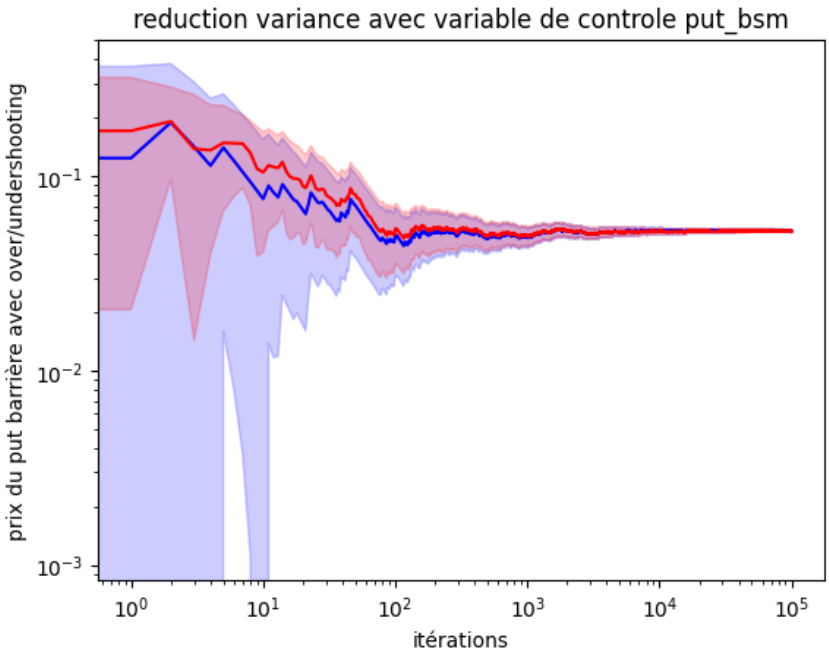

FIGURE 9 – Réduction de variance avec la méthode des variables de contrôle - Résultats numériques : esperance base = 0.05483, std base = 0.09849, esperance contrôle = 0.05209, std contrôle = 0.09449

Objectif 2

Utiliser la relation de parité Call Put afin de trouver comme dans le cours une autre variable de contrôle.

$$\beta(e^{-r(T-t)}S_T - S_t)$$

Vous pouvez donner également un regard critique sur vos résultats précédents.

On utilise la variable :

$$Z = e^{-r(T-t)}S_T - S_t$$

On a :

$$E[Z] = 0$$

On construit alors :

$$X^* = X - \beta Z$$

Cette variable est alors directement liée à la dynamique du sous-jacent.

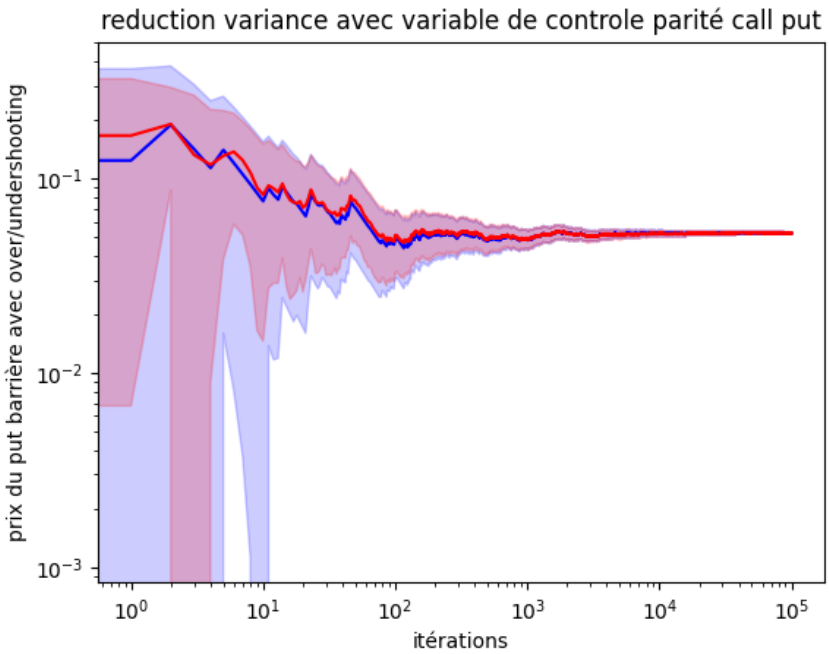

FIGURE 10 – Réduction de variance avec la méthode des variables de contrôle aidé de la parité Call Put - Résultats numériques : esperance base = 0.05483, std base = 0.09849, esperance contrôle = 0.05226, std contrôle = 0.09265

Voir le code 2.2

2.3 Sensibilité aux paramètres

Objectif

Fournissez une étude qualitative et quantitative sur la sensibilité au strike et à la barrière. Comparer également au prix du Put sans barrière desactivante.

On a :

$$Put_{barriere} \leq Put_{classique}$$

car :

$$\mathbb{1}_{T<\tau_D} \leq 1$$

Le put classique correspond alors au cas limite :

$$L \to 0$$

A/ Sensibilité au strike : Le prix du put est croissant en K :

$$\frac{\partial Put}{\partial K} > 0$$

Le comportement reste similaire pour le put barrière.

B/ Sensibilité à la barrière : Quand L augmente :

— La probabilité de désactivation augmente
— Le prix du produit diminue

Donc :

$$\frac{\partial Put}{\partial L} < 0$$

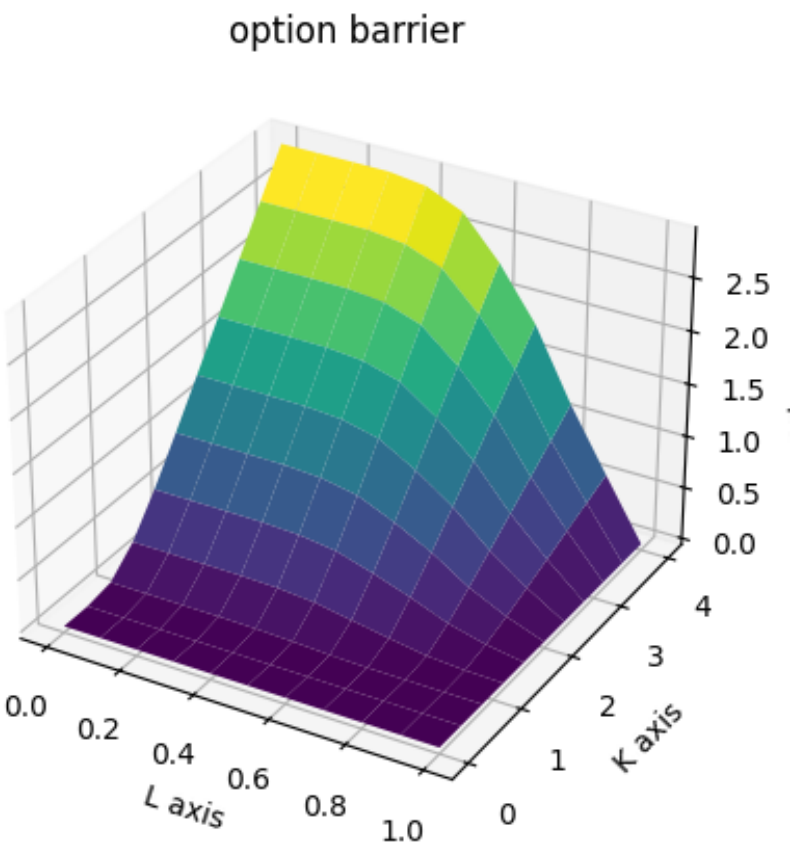

FIGURE 11 – Evolution de l'option barrière en fonction de ses paramètres

Voir le code en 2.3

3 Exercice 3 : Plusieurs sous-jacents

Le but de cet exercice est de trouver le prix de produit ayant le payoff suivant :

Nous essayons ici de trouver le prix de ce produit dans le modèle de Black Scholes. C'est à dire

$$\mathbb{E}\left[e^{-r(T-t)}\Phi(S_1,S_2,S_3,K)|\mathcal{F}_t\right] = \mathbb{E}\left[e^{-r(T-t)}\left(K-\sum_{i=1}^{3}\frac{1}{S_i(t)(T-t)}\int_t^T S_i(s)ds\right)_+|\mathcal{F}_t\right] = ?$$

$$S_i(T) = S_i(t)e^{(r-\frac{\sigma_i^2}{2})(T-t)+\sigma_i(W_T^i-W_t^i)}$$

La matrice de corrélation et la décomposition de Cholesky sont les suivantes

$$\begin{pmatrix} 1 & \rho_{12} & \rho_{13} \\ \rho_{12} & 1 & \rho_{23} \\ \rho_{13} & \rho_{23} & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0.25 & 0.25 \\ 0.25 & 1 & 0.25 \\ 0.25 & 0.25 & 1 \end{pmatrix}, \begin{pmatrix} 1 & 0 & 0 \\ 0.25 & 0.97 & 0 \\ 0.25 & 0.19 & 0.95 \end{pmatrix}$$

3.1 Pricing

Objectif

En utilisant le schéma de discrétisation d'Euler, evaluer le prix du produit précédent. Vous pouvez choisir le générateur de nombre aléatoire que vous souhaitez.

Les paramètres numériques seront les suivants :

$$\begin{aligned} S_1(t) &= 1., & S_2(t) &= 1.5, & S_3(t) &= 1.3 \\ \sigma_1 &= 0.15, & \sigma_2 &= 0.2, & \sigma_3 &= 0.25 \\ T-t &= 2, & r &= 0.02, & K &= 3. \end{aligned}$$

On rapelle que la décomposition de Cholesky consiste, pour une matrice symétrique définie positive Γ, à déterminer une matrice triangulaire inférieure L telle que : $\Gamma = LL^T$.

Pour simuler nos trois sous-jacents $S_i, i \in \{1,2,3\}$, nous allons devoir simuler trois gaussiennes indépendantes $\mathcal{N}(0,1)$, qu'on nommera $Z^i, i \in \{1,2,3\}$, grâce à un générateur de nombre aléatoire, puis implémenter la dépendance entre ces variables aléatoires, de telle sorte que le vecteur gaussien $Z = (Z^1, Z^2, Z^3)$ en résultant ait pour matrice de covariance Γ.

En posant $X = LZ$ (L la matrice de décomposition de Cholesky de Γ), on a bien :

$$Cov(X) = \mathbb{E}[(LZ)(LZ)^T] = \mathbb{E}[LZZ^TL^T] = L\mathbb{E}[ZZ^T]L^T \underset{*}{=} LL^T = \Gamma$$

$*$: on rapelle que les Z^i sont indépendants, donc $Cov(Z) = I_3$ donc, car Z est centré, $\mathbb{E}[ZZ^T] = I_3$

On a donc bien que $X = LZ$ vérifie les conditions de dépendances pour le pricing que nous allons faire. On a donc finalement le vecteur de browniens correlés qui peut être exprimé et simulé ainsi :

$$\begin{pmatrix} W_t^1 \\ W_t^2 \\ W_t^3 \end{pmatrix} = L \begin{pmatrix} Z_t^1 \\ Z_t^2 \\ Z_t^3 \end{pmatrix} \sqrt{t}$$

Après avoir montré comment on allait simuler le vecteur demandé, on va s'interesser à la traduction du problème sous forme de schéma d'Euler. On utilisera ce schéma pour la simulation de Monte Carlo.

On va approcher l'intégrale présente dans le payoff par une somme de Riemann. C'est à dire que, en séparant $[t, T]$ en N pas de temps de taille $\Delta s = \frac{T-t}{N}$.

$$\sum_{n=0}^{N-1} S_i(s_n)\Delta s \sim \int_t^T S_i(s)ds$$

On écrit la version discretisée de S_i tel que, $\forall i \in \{1, 2, 3\}$ and $\forall n \in \{0, ..., N-1\}$

$$S_i(s_{n+1}) = S_i(s_n) \exp\left((r - \frac{\sigma_i^2}{2})\Delta s + \sigma_i\sqrt{\Delta s}\sum_{j=1}^{i} L_{ij}Z_{n+1}^j\right)$$

où $Z_{n+1}^j \sim \mathcal{N}(0, 1)$ sont indépendantes et les L_{ij} les coefficients de L (L est un triangle inférieur). La formule utilise le fait que pour chaque pas de temps Δt, on génère trois nombres gaussiens indépendants z_1, z_2, z_3 et qu'on obtient les dW^i nécessaires au calcul du prix en calculant :

$$\begin{aligned}
dW_1 &= L_{11}z_1\sqrt{\Delta t} = z_1\sqrt{\Delta t} \\
dW_2 &= (L_{21}z_1 + L_{22}z_2)\sqrt{\Delta t} = (0.25 \cdot z_1 + 0.97 \cdot z_2)\sqrt{\Delta t} \\
dW_3 &= (L_{31}z_1 + L_{32}z_2 + L_{33}z_3)\sqrt{\Delta t} = (0.25 \cdot z_1 + 0.19 \cdot z_2 + 0.95 \cdot z_3)\sqrt{\Delta t}
\end{aligned}$$

Enfin, on passe au pricing en mettant en place l'algorithme de Monte Carlo. Dans notre cas, on doit estimer l'espérance suivante sous la probabilité risque-neutre :

$$P_t = \mathbb{E}\left[e^{-r(T-t)}\left(K - \frac{1}{T-t}\sum_{i=1}^{3}\frac{1}{S_i(t)}\int_t^T S_i(s)ds\right)_+ \middle| \mathcal{F}_t\right]$$

— On génère M trajectoires pour les 3 actifs corrélés sur N pas de temps.

— Pour chaque trajectoire m, on calcul la valeur $\Phi^{(m)}$:

$$\Phi^{(m)} = \left(K - \sum_{i=1}^{3}\frac{1}{S_i(t)(T-t)}\left[\sum_{n=0}^{N-1} S_i(s_n)^{(m)}\Delta s\right]\right)_+$$

— L'estimateur du prix est la moyenne des payoffs actualisés :

$$\boxed{\hat{P}_t = e^{-r(T-t)}\frac{1}{M}\sum_{m=1}^{M}\Phi^{(m)}}$$

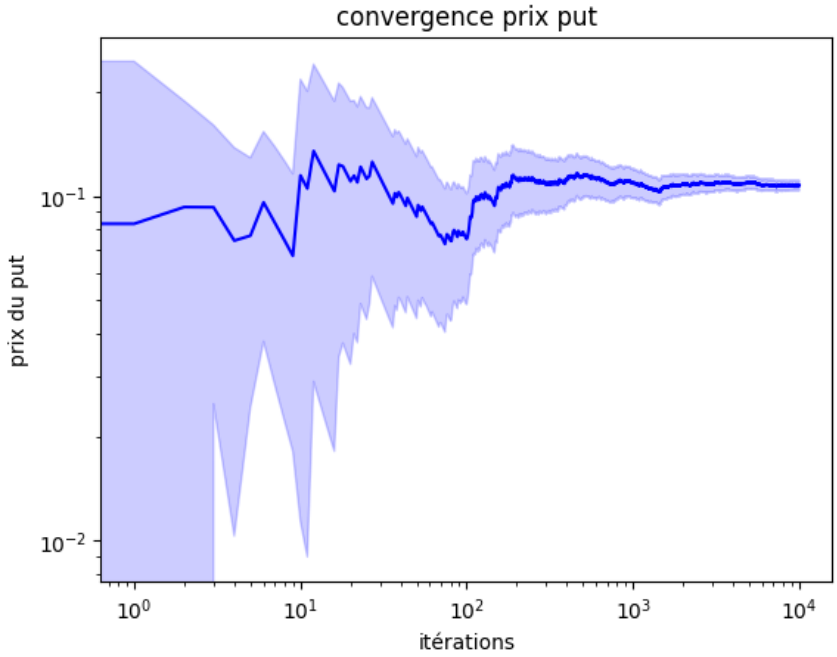

FIGURE 12 – Pricing d'option asiatique à plusieurs sous-jacents. Résultats numériques : esperance = 0.107446, std = 0.163757

Voir le code 3.1

3.2 Réduction de variance

Objectif

En utilisant les variables de contrôle, utiliser les puts européens afin de réduire la variance.

$$
\begin{aligned}
&\mathbb{E}\left[e^{-r(T-t)}\Phi(S_1,S_2,S_3,K) \mid \mathcal{F}_t\right] \\
=&\mathbb{E}\left[e^{-r(T-t)}\Phi(S_1,S_2,S_3,K) \mid \mathcal{F}_t\right] \\
&+\sum_{i=1}^{3}\beta_i\Bigg(Put_{BS}(\tilde{S}_i,K_i,r,\tilde{\sigma}_i,T) \\
&\qquad -\mathbb{E}\left[e^{-r(T-t)}(K_i-\tilde{S}_i(T))_+ \mid \mathcal{F}_t\right]\Bigg) \\
=&\mathbb{E}\left[e^{-r(T-t)}\left(\Phi(S_1,S_2,S_3,K)-\sum_{i=1}^{3}\beta_i(K_i-\tilde{S}_i(T))_+\right) \mid \mathcal{F}_t\right] \\
&+\sum_{i=1}^{3}\beta_i Put_{BS}(\tilde{S}_i,K_i,r,\tilde{\sigma}_i,T)
\end{aligned}
$$

On choisira $\tilde{S}_i(t) = S_i(t) = K_i$ et $\tilde{\sigma}_i = \sigma_i$ De plus, β_i n'est pas précisé.

L'objectif est d'estimer le prix du produit, c'est-à-dire l'espérance conditionnelle du payoff actualisé

$$\mathbb{E}\big[e^{-r(T-t)}\Phi(S_1, S_2, S_3, K) \mid \mathcal{F}_t\big],$$

où

$$\Phi(S_1, S_2, S_3, K) = \left(K - \sum_{i=1}^{3} \frac{1}{S_i(t)(T-t)} \int_t^T S_i(s)\, ds\right)_+.$$

Afin de réduire la variance de l'estimateur de Monte Carlo, on utilise la méthode des variables de contrôle, comme présentée dans le cours.

On note

$$X = e^{-r(T-t)}\Phi(S_1, S_2, S_3, K)$$

la variable aléatoire dont on cherche l'espérance. On introduit un vecteur de variables de contrôle

$$Z = (Z_1, Z_2, Z_3),$$

où, pour tout $i \in \{1, 2, 3\}$,

$$Z_i = e^{-r(T-t)}(K_i - \tilde{S}_i(T))_+ - \mathbb{E}\Big[e^{-r(T-t)}(K_i - \tilde{S}_i(T))_+\Big].$$

Par construction, Z est centré, c'est-à-dire $\mathbb{E}[Z_i] = 0$.
Pour tout vecteur $\beta = (\beta_1, \beta_2, \beta_3)$, on définit alors

$$X(\beta) = X - \sum_{i=1}^{3} \beta_i Z_i.$$

On a alors,

$$\mathbb{E}[X(\beta)] = \mathbb{E}[X],$$

mais on a aussi que la variance de $X(\beta)$ est réduite lorsque les variables de contrôle sont fortement corrélées avec X.

On choisit comme variables de contrôle des puts européens dans le modèle de Black-Scholes, comme précisé dans l'énoncé, car la formule fermée leur espérance est connue. L'énoncé nous dit de prendre :

$$\tilde{S}_i(t) = S_i(t), \qquad K_i = S_i(t), \qquad \tilde{\sigma}_i = \sigma_i.$$

Pour chaque $i \in \{1, 2, 3\}$, le prix du put (calculé précédement) s'écrit

$$Put_{BS}^{(i)} = K_i e^{-r(T-t)}\mathcal{N}(-d_2^{(i)}) - S_i(t)\mathcal{N}(-d_1^{(i)}),$$

avec

$$d_1^{(i)} = \frac{\ln(S_i(t)/K_i) + (r + \frac{1}{2}\sigma_i^2)(T-t)}{\sigma_i\sqrt{T-t}}, \qquad d_2^{(i)} = d_1^{(i)} - \sigma_i\sqrt{T-t}.$$

Comme $K_i = S_i(t)$, on obtient

$$Put_{BS}^{(i)} = S_i(t)\big[e^{-r(T-t)}\mathcal{N}(-d_2^{(i)}) - \mathcal{N}(-d_1^{(i)})\big].$$

Après avoir exprimé les variables de contrôle, on va estimer de nouveau avec la méthode de Monte Carlo et la formule fermée, puis estimer les coefficients β_i.

On a alors la formule :

$$\mathbb{E}[X] = \mathbb{E}\left[e^{-r(T-t)}\Big(\Phi(S_1, S_2, S_3, K) - \sum_{i=1}^{3} \beta_i (K_i - \tilde{S}_i(T))_+\Big)\right] + \sum_{i=1}^{3} \beta_i Put_{BS}^{(i)}.$$

La première espérance est estimée par Monte Carlo, tandis que la seconde est calculée exactement à l'aide de la formule de Black–Scholes.

Le choix optimal des coefficients β, au sens de la minimisation de la variance, est donné d'aprèsle cours, par

$$\beta^* = \big(\mathbb{E}[ZZ^\top]\big)^{-1}\mathbb{E}[XZ],$$

ce qui se calcul composante par composante avec :

$$\beta_i^* = \frac{\mathrm{Cov}(X, Z_i)}{\mathrm{Var}(Z_i)}.$$

En pratique, ces quantités sont estimées à partir de M trajectoires simulées par

$$\boxed{\beta_M^* = \left[\frac{1}{M}\sum_{m=1}^{M} Z_m Z_m^\top\right]^{-1} \frac{1}{M}\sum_{m=1}^{M} X_m Z_m.}$$

Remarque

Comme dans la question 3.1, l'intégrale intervenant dans Φ est approchée par une somme de Riemann sur N pas de temps, avec $\Delta t = \frac{T-t}{N}$:

$$\int_t^T S_i(s)\, ds \approx \Delta t \sum_{n=0}^{N-1} S_i(t_n).$$

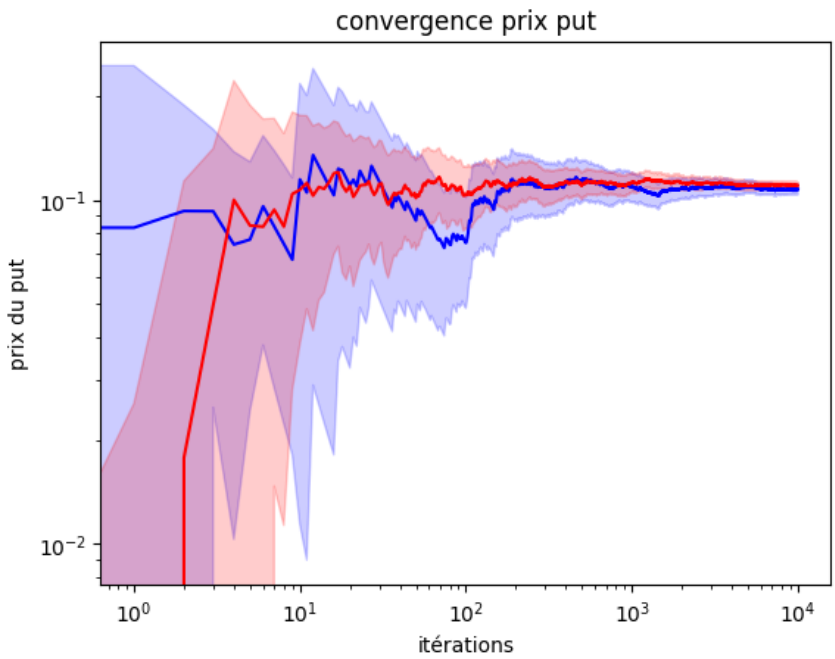

FIGURE 13 – Réduction de variance avec variable de contrôle : esperance originale = 0.107446, std originale = 0.163758, esperance avec contrôle = 0.1104747, std avec contrôle = 0.11580547.

Voir le code 3.2

3.3 Bonus : Réduction de variance par la méthode de Kemna–Vorst

Objectif

En s'inspirant de la méthode de Kemna Vorst pour les variables de contrôles dans le cas des option asiatiques unidimensionel, appliquer l'inégalité de Jensen pour trouver des variables de contrôles adaptés à notre problème.
On choisira $\tilde{S}_i(t)$ et $\tilde{\sigma}_i$ comme dans le cours. De plus, β_i n'est pas précisé et $K_i = S_i(t)$.

Dans la littérature, la méthode de Kemna Vorst cherche à démontrer que l'intégrale

$$A_i = \frac{1}{T-t}\int_t^T S_i(s)\,ds$$

peut être contrôlée efficacement par sa version geométrique :

$$G_i = \exp\left(\frac{1}{T-t}\int_t^T \ln S_i(s)\,ds\right),$$

ce qui va nous permettre de déduire une formule fermée pour un put géométrique, qui sert ensuite comme variable de contrôle. On va faire toutes les démonstrations dans les sections qui viennent.

1.Hypothèses

On rappelle pour chaque sous-jacent S_i, on a :

$$S_i(s) = S_i(t) \exp\left((r - \tfrac{1}{2}\sigma_i^2)(s-t) + \sigma_i(W_i(s) - W_i(t))\right),$$

où (W_1, W_2, W_3) est un brownien à trois dimensions, avec la matrice de corrélation donnée dans l'énoncé du début de l'exercice.

On a alors que $\ln S_i(s)$ (possible car l'actif est strictement positif) est une variable normale dont l'espérance et la variance sont calculables explicitement :

$$\ln S_i(s) = \ln S_i(t) + (r - \tfrac{1}{2}\sigma_i^2)(s-t) + \sigma_i(W_i(s) - W_i(t)).$$

2. Inégalité de Jensen

On note la moyenne arithmétique (sous forme intégrale) :

$$A_i = \frac{1}{T-t}\int_t^T S_i(s)\,ds.$$

Comme la fonction $\ln x$ est concave, l'inégalité de Jensen nous donne :

$$\ln(A_i) = \ln\left(\frac{1}{T-t}\int_t^T S_i(s)\,ds\right) \geq \frac{1}{T-t}\int_t^T \ln S_i(s)\,ds.$$

En passant ensuite à l'exponentielle, on a :

$$\boxed{A_i \geq \exp\left(\frac{1}{T-t}\int_t^T \ln S_i(s)\,ds\right) = G_i}$$

Cette quantité est strictement plus petite que A_i presque sûrement, et surtout, elle est très corrélée aux variations du sous-jacent. C'est ce qui justifie son utilisation comme variable de contrôle.

3. Loi de l'intégrale

On montre que la quantité :

$$I_i = \frac{1}{T-t}\int_t^T \ln S_i(s)\,ds$$

suit une loi normale. En effet :

Si on part de l'expression logarithmique :

$$\ln S_i(s) = \ln S_i(t) + (r - \tfrac{1}{2}\sigma_i^2)(s-t) + \sigma_i(W_i(s) - W_i(t)).$$

L'intégrale I_i devient :

$$\ln S_i(t) + (r - \tfrac{1}{2}\sigma_i^2)\frac{1}{T-t}\int_t^T (s-t)\,ds + \sigma_i\frac{1}{T-t}\int_t^T (W_i(s) - W_i(t))\,ds.$$

Les deux premières intégrales donnent :

$$\frac{1}{T-t}\int_t^T (s-t)\,ds = \frac{1}{T-t}\cdot\frac{(T-t)^2}{2} = \frac{T-t}{2}.$$

Pour la troisième intégrale, on considère un brownien standard $(B(s))_{s\geq 0}$. Comme l'intégrale d'un processus gaussien centré est encore gaussienne centrée, il suffit de calculer la variance. On veut calculer :

$$\mathrm{Var}\left(\int_0^T B(s)\,ds\right) = \mathbb{E}\left[\left(\int_0^T B(s)\,ds\right)^2\right]. = \mathbb{E}\left[\int_0^T \int_0^T B(s)B(u)\,ds\,du\right].$$

Par linéarité de l'espérance :

$$= \int_0^T \int_0^T \mathbb{E}[B(s)B(u)]\,ds\,du.$$

Or pour un brownien standard :

$$\mathbb{E}[B(s)B(u)] = \min(s,u).$$

Donc :

$$\mathrm{Var}\left(\int_0^T B(s)\,ds\right) = \int_0^T \int_0^T \min(s,u)\,ds\,du.$$

On découpe selon $u \leq s$ et $u \geq s$:

$$= \int_0^T \left(\int_0^s u\,du + \int_s^T s\,du\right) ds.$$

Calcul des deux intégrales internes :

$$\int_0^s u\,du = \frac{s^2}{2},$$

$$\int_s^T s\,du = s(T-s).$$

Donc :

$$= \int_0^T \left(\frac{s^2}{2} + s(T-s)\right) ds.$$

On simplifie l'intérieur :

$$\frac{s^2}{2} + sT - s^2 = sT - \frac{s^2}{2}.$$

Donc :

$$= \int_0^T \left(sT - \frac{s^2}{2}\right) ds.$$

On intègre terme à terme :

$$\int_0^T sT\,ds = T\frac{T^2}{2} = \frac{T^3}{2},$$

$$\int_0^T \frac{s^2}{2}\,ds = \frac{1}{2}\frac{T^3}{3} = \frac{T^3}{6}.$$

Ainsi :

$$\mathrm{Var}\left(\int_0^T B(s)\,ds\right) = \frac{T^3}{2} - \frac{T^3}{6} = \frac{T^3}{3}.$$

Maintenant pour

$$\int_t^T (W_i(s) - W_i(t))\,ds,$$

le processus $(W_i(s) - W_i(t))_{s\geq t}$ est un brownien qu'on peut donc écrir sous la forme $B(s-t)$.

On pose $u = s - t$, alors :

$$\int_t^T (W_i(s) - W_i(t))\,ds = \int_0^{T-t} B(u)\,du.$$

Par le résultat précédent :

$$\mathrm{Var} = \frac{(T-t)^3}{3}.$$

Donc :

$$\boxed{\int_t^T (W_i(s) - W_i(t))\,ds \sim \mathcal{N}\left(0, \frac{(T-t)^3}{3}\right).}$$

On en déduit que I_i est normale :

$$\boxed{I_i \sim \mathcal{N}\big(\mu_{I_i},\ \sigma_{I_i}^2\big)}$$

avec

$$\mu_{I_i} = \ln S_i(t) + (r - \tfrac{1}{2}\sigma_i^2)\frac{T-t}{2}, \qquad \sigma_{I_i}^2 = \sigma_i^2\frac{T-t}{3}.$$

4. Détermination de la loi G_i

Par définition,

$$G_i = \exp(I_i).$$

Donc G_i est une variable log-normale :

$$\ln G_i \sim \mathcal{N}(\mu_{I_i}, \sigma_{I_i}^2).$$

Or pour une loi lognormale, on a :

$$\mathbb{E}[e^X] = \left(\mu + \frac{\sigma^2}{2}\right)$$

D'où,

$$\mathbb{E}[G_i] = \left(\mu_{I_i} + \frac{\sigma_{I_i}^2}{2}\right)$$

Son spot équivalent s'obtient en prenant l'espérance exponentielle :

$$G_i(t) = \exp\Big(\mu_{I_i}\Big) = S_i(t)\ \exp\left(\frac{r - \sigma_i^2/2}{2}(T-t)\right).$$

La variance est

$$\sigma_{G_i} = \sigma_i\sqrt{\frac{T-t}{3}}.$$

5. Formule finale

Nous considérons le put

$$(K_i - G_i)_+.$$

Puisque G_i est log-normal avec les paramètres trouvés juste avant, son prix avec Black Scholes est :

$$Put_{GV}^{(i)} = K_i e^{-r(T-t)}\mathcal{N}(-\tilde{d}_2^{(i)}) - G_i(t)\mathcal{N}(-\tilde{d}_1^{(i)}),$$

où

$$\tilde{d}_1^{(i)} = \frac{\ln\left(\frac{G_i(t)}{K_i}\right) + \left(r + \frac{1}{6}\sigma_i^2\right)(T-t)}{\sigma_i\sqrt{\frac{T-t}{3}}}, \qquad \tilde{d}_2^{(i)} = \tilde{d}_1^{(i)} - \sigma_i\sqrt{\frac{T-t}{3}}.$$

On pose enfin :

$$Z_i = e^{-r(T-t)}(K_i - G_i^{(N)})_+ - Put_{GV}^{(i)}.$$

Et l'estimateur de contrôle, d'après le cours, est de la forme :

$$\widehat{X}_{cv} = \widehat{X} - \sum_{i=1}^{3}\beta_i Z_i + \sum_{i=1}^{3}\beta_i Put_{GV}^{(i)},$$

où

$$\beta_i^* = \frac{\mathrm{Cov}(X, Z_i)}{\mathrm{Var}(Z_i)}.$$

Ce contrôle est censé être meilleur car A_i et G_i ont une corrélation très forte.

4 Exercice 4 : Computing Greeks

Rappelons le prix du Put dans le modèle de Black Scholes.

$$Put_{BS}(S_t, K, r, \sigma, T) = \mathbb{E}\left[e^{-r(T-t)}(K - S_T)_+ | \mathcal{F}_t\right]$$

$$S_T = S_t e^{(r - \frac{\sigma^2}{2})(T-t) + \sigma(W_T - W_t)}$$

Nous définissons les dérivées partielles de la manière suivante :

— Delta : $\partial_S Put_{BS}$
— Gamma : $\partial_S S Put_{BS}$
— Vega : $\partial_\sigma Put_{BS}$

Les paramètres numériques seront les suivants :

$$S_t = 1, r = 0.02, t = 0, T = 4, \sigma = 0.3, K = 0.8$$

Vous utiliserez comme nombre aléatoire la suite de Van der Corput avec le nombre premier de votre choix.

4.1 Méthode numérique

Finite difference method

Calculez la dérivée partielle de chaque Grecque en utilisant la méthode des différences finies.

Pour rappel, la méthode des différences finies consiste à substituer aux dérivées les taux de variation de la fonction inconnue entre les points voisins.

D'après l'approximation centrale de premier et deuxième ordre ordre, on a :

$$\forall f \in \mathcal{C}^1, f'(x) \approx \frac{f(x+\epsilon) - f(x-\epsilon)}{2\epsilon}$$

$$\forall f \in \mathcal{C}^2, f''(x) \approx \frac{f(x+\epsilon) - 2f(x) + f(x-\epsilon)}{2\epsilon}$$

On applique ces formules au prix du put européen $Put_{BS}(S, \sigma)$ estimé par Monte Carlo. On a alors les Grecques demandées :

$$\Delta = \partial_S Put_{BS}(S, \sigma) \approx \frac{Put_{BS}(S+\epsilon, \sigma) - Put_{BS}(S-\epsilon, \sigma)}{2\epsilon}.$$

$$\Gamma = \partial_{SS} Put_{BS}(S, \sigma) \approx \frac{Put_{BS}(S+\epsilon, \sigma) - 2Put_{BS}(S, \sigma) + Put_{BS}(S-\epsilon, \sigma)}{\epsilon^2}.$$

$$\text{Vega} = \partial_\sigma Put_{BS}(S, \sigma) \approx \frac{Put_{BS}(S, \sigma+\epsilon) - Put_{BS}(S, \sigma-\epsilon)}{2\epsilon}.$$

Afin de réduire la variance des estimateurs, les mêmes réalisations des normales sont utilisées pour les perturbations positives et négatives.

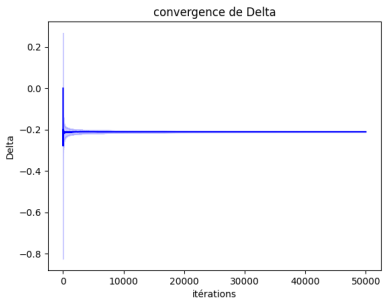

FIGURE 14 – Convergence du Delta avec la méthode des différences finies : esperance = -0.21034, std = 0.26508

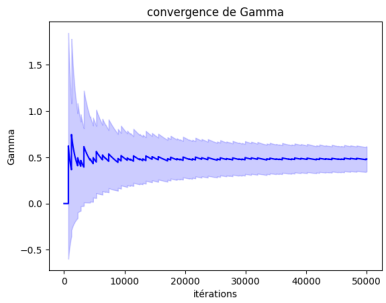

FIGURE 15 – Convergence du Gamma avec la méthode des différences finies : esperance = 0.48045, std = 15.345

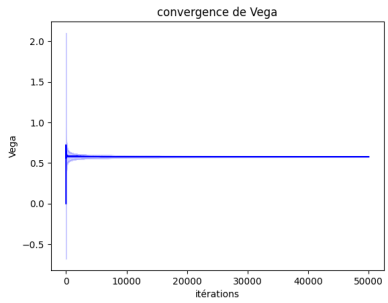

FIGURE 16 – Convergence du Vega avec la méthode des différences finies : esperance = 0.57699, std = 0.68200

Les simulations sont dans le code (**Voir le code 4.1**)

Pathwise Differentiation method

Calculez la dérivée partielle de chaque Grecque en utilisant la "Pathwise Differentiation method".

De manière générale, la Pathwise Differentiation method consiste à dériver directement les trajectoires individuelles d'un système par rapport à un paramètre pour estimer la sensibilité d'une espérance. Au lieu de comparer deux simulations différentes, on calcule comment une seule et même simulation evoluerait si on changeait légèrement le paramètre d'entrée.

Dans notre cas, on a bien notre Payoff qui est continue et dérivable, On va donc calculer la formule des grecques en dérivant directement ce qui est dans l'espérance, puis on réalisera un Monte Carlo. Attention cependant, pour le Γ qui est la dérivée de la dérivée du Δ, on va avoir un problème car la dérivée du Δ n'est pas dérivable (le Δ n'est pas deux fois dérivable)

On écrit de nouveau le put :

$$Put_{BS}(S_t, K, r, \sigma, T) = \mathbb{E}\left[e^{-r(T-t)}(K - S_T)_+ | \mathcal{F}_t\right]$$

Donc, en notant

$$f(S_T) = e^{-r(T-t)}(K - S_T)_+$$

,

$$\Delta = \frac{\partial}{\partial S_0}\mathbb{E}[f(S_T)] = \mathbb{E}\left[\frac{\partial f}{\partial S_T} \cdot \frac{\partial S_T}{\partial S_0}\right]$$

Or avec $S_T = S_t e^{(r-\frac{\sigma^2}{2})(T-t)+\sigma(W_T-W_t)}$, on a :

$$\frac{\partial f}{\partial S_T} = e^{-r(T-t)} \cdot (-\mathbb{1}_{S_T<K})$$
$$\frac{\partial S_T}{\partial S_0} = \frac{S_T}{S_0}$$

D'où

$$\Delta = \mathbb{E}\left[e^{-r(T-t)} \cdot (-1_{S_T<K}) \cdot \frac{S_T}{S_0}\right]$$

Dans le cas du Vega, on a les mêmes calculs :

$$\Delta = \frac{\partial}{\partial S_0}\mathbb{E}[f(S_T)] = \mathbb{E}\left[\frac{\partial f}{\partial S_T} \cdot \frac{\partial S_T}{\partial \sigma}\right]$$

Avec,

$$\frac{\partial f}{\partial S_T} = e^{-r(T-t)} \cdot (-\mathbb{1}_{S_T<K})$$
$$\frac{\partial S_T}{\partial S_0} = S_T \cdot (-\sigma(T-t) + \sqrt{(T-t)}Z)$$

Et donc,

$$Vega = \mathbb{E}\left[e^{-r(T-t)} \cdot (-1_{S_T<K}) \cdot S_T\Big(- \sigma(T-t) + \sqrt{(T-t)}Z\Big)\right]$$

Les calculs de ces deux quantité sont effectuée en dans le code (**Voir le code 4.1**) par méthode de Monte Carlo. On voit bien que le $-1_{S_T<K}$ empêche de dériver une seconde fois et donc dobtenir le Γ avec cette méthode.

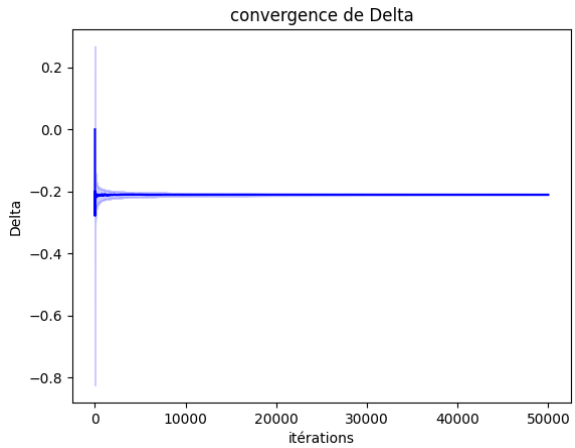

FIGURE 17 – Convergence du Delta avec la méthode Pathwise differentation : esperance = -0.21034, std = 0.26530

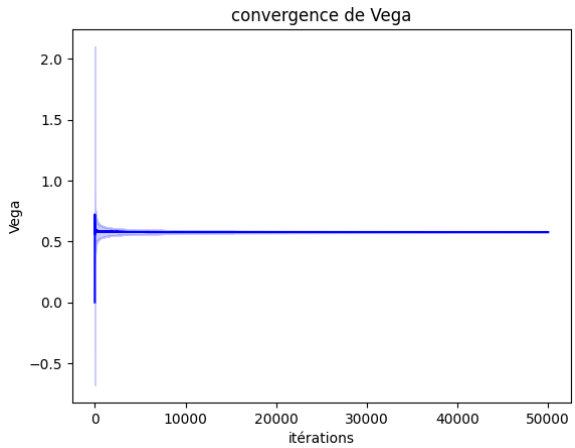

FIGURE 18 – Convergence du Vega avec la méthode Pathwise differentation : esperance = 0.57698, std = 0.68237

Log Likelihood method

Calculez la dérivée partielle de chaque Grecque en utilisant la "Log Likelihood method".

Pour la Log Likelihood method, on va dériver la densité de probabilité du sous-jacent plutôt que son payoff (ce qui nous permet de calculer Γ cette fois ci). On a le prix du Put qui vaut toujours :

$$Put_{BS}(S_t, K, r, \sigma, T) = \mathbb{E}\left[e^{-r(T-t)}(K - S_T)_+ | \mathcal{F}_t\right]$$

Lemme

Rappelons que d'après le cours, on a de manière générale la relation suivante :

Soit $P(\theta) = e^{-rT}\mathbb{E}[\phi(S_T)]$ le prix d'une option dépendant d'un paramètre θ. En notant $g(x,\theta)$ la densité de la variable aléatoire S_T, nous avons :

$$P(\theta) = e^{-rT}\int_{\mathbb{R}} \phi(x)g(x,\theta)dx$$

En dérivant sous l'intégrale par rapport à θ (interversion autorisée par la régularité de la densité log-normale) :

$$\partial_\theta P(\theta) = e^{-rT}\int_{\mathbb{R}} \phi(x)\frac{\partial_\theta g(x,\theta)}{g(x,\theta)}g(x,\theta)dx$$

En utilisant la relation $\partial_\theta \log g = \frac{\partial_\theta g}{g}$, on obtient l'estimateur LRM :

$$\partial_\theta P(\theta) = \mathbb{E}\left[e^{-rT}\phi(S_T)\partial_\theta \log g(S_T,\theta)\right]$$

$$\int_t^T S_i(s)\,ds \approx \Delta t \sum_{n=0}^{N-1} S_i(t_n).$$

Dans le cas du Put donné dans l'exercice, on utilise la variable normale centrée réduite $Z = \frac{W_T}{\sqrt{T}}$. D'après l'exercice 1, la densité g de S_T est liée à la densité f de la loi normale par la relation $\ln g(S_T,\theta) = -\frac{1}{2}\ln(2\pi) - \frac{z^2}{2} - \ln(S_T\sigma\sqrt{T})$, avec :

$$z = \frac{\ln(S_T/S_0) - (r - \frac{\sigma^2}{2})T}{\sigma\sqrt{T}}$$

Pour le Δ, on a :

On dérive par rapport à S_0 :

$$\frac{\partial \log g}{\partial S_0} = \frac{\partial \log g}{\partial z}\frac{\partial z}{\partial S_0} = (-z)\times\left(-\frac{1}{S_0\sigma\sqrt{T}}\right) = \frac{z}{S_0\sigma\sqrt{T}}$$

En remplaçant z par $\frac{W_T}{\sqrt{T}}$, on obtient le poids vu en cours :

$$\Delta_{Like} = \mathbb{E}\left[e^{-rT}(K-S_T)_+\frac{W_T}{S_0\sigma T}\right]$$

De la même manière, pour $Vega$:
En dérivant par rapport à σ, on obtient :

$$\frac{\partial \log g}{\partial \sigma} = -\frac{1}{\sigma} - z\frac{\partial z}{\partial \sigma} \implies \text{Vega}_{Like} = \mathbb{E}\left[e^{-rT}(K-S_T)_+\left(\frac{W_T^2 - T}{\sigma T} - W_T\right)\right]$$

Enfin, pour Γ :
Le Gamma est la dérivée seconde. Le cours donne la forumle suivante $\frac{\partial^2 g}{g} = \partial^2_{S_0}\log g + (\partial_{S_0}\log g)^2$. Après remplacement des dérivées de z, on aboutit à :

$$\Gamma_{Like} = \mathbb{E}\left[e^{-rT}(K-S_T)_+\frac{1}{S_0^2\sigma T}\left(\frac{W_T^2}{\sigma T} - W_T - \frac{1}{\sigma}\right)\right]$$

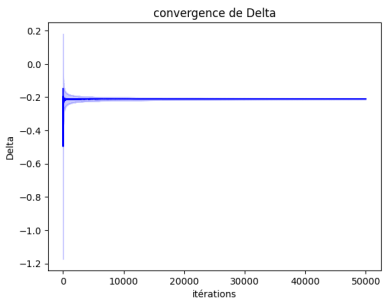

FIGURE 19 – Convergence du Delta avec la méthode de la Log Likelihood : esperance = -0.21039, std = 0.43984

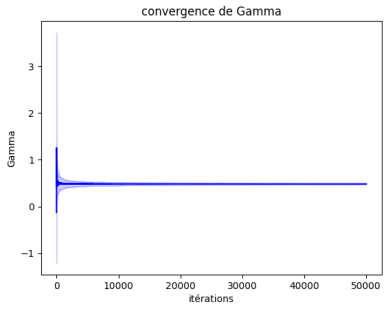

FIGURE 20 – Convergence du Gamma avec la méthode de la Log Likelihood : esperance = 0.48104, std = 1.7034

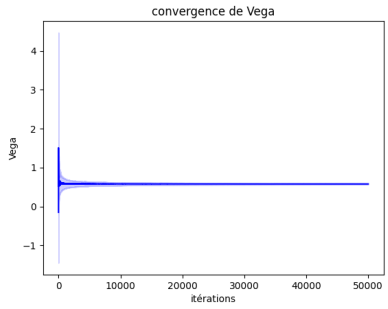

FIGURE 21 – Convergence du Vega avec la méthode de la Log Likelihood : esperance = 0.57725, std = 2.0441

Numériquement, la simulation est données dans le code (**Voir le code 4.1**)

4.2 Comparaison

Objectif

Comparer les différentes méthodes entre elles et avec les formules fermées que vous aurez trouvé préalablement. Faire également une étude qualitative et quantitative des différentes méthodes utilisées.

Le tableau suivant montre les résultats obtenus pour les paramètres $S_0 = 1, K = 0.8, r = 0.02, \sigma = 0.3, T = 4$. Les valeurs de référence sont calculées via les formules fermées de Black-Scholes calculées précédemment.

Méthode	**Delta (Δ)**	**Vega (ν)**	**Gamma (Γ)**
Différences Finies	-0.21035	0.57699	0.48045
Pathwise	-0.21033	0.57698	-
Likelihood Ratio	-0.21039	0.57724	0.48104
Formule Fermée	**-0.21034**	**0.57700**	**0.48046**

TABLE 1 – Comparaison des estimations des Grecques ($M = 50\,000$ simulations)

On peut alors discuter ensuite des avantages et des inconvénients au cas par cas :

Méthode	Avantages	Inconvénients
Différences Finies	• Facile à implémenter • Modèle "boîte noire" (pas de dérivées)	• Biais dû au choix de h • Très coûteux computationnellement • Convergence lente pour Γ
Pathwise	• Variance la plus faible • Très rapide (une simulation) • Sans biais	• Payoff continu requis • Souvent impossible pour Γ
Likelihood Ratio	• Gère les payoffs discontinus • Permet le calcul de Γ • Pas de dérivée du payoff	• Densité de probabilité requise • Convergence un peu plus lente que Pathwise

TABLE 2 – Synthèse comparative des méthodes de calcul des Greeks

L'analyse des résultats montre que la méthode Pathwise est la plus efficace pour le Δ et le Vega car elle exploite directement la sensibilité de la trajectoire, ce qui réduit considérablement le bruit de Monte Carlo.

Cependant, pour le Γ, la méthode Likelihood est plus robuste car elle ne dépend pas de la régularité du payoff. Les finite differences restent utiles car simple a implémenter mais donnent des convergence moins fortes. On notera que l'utilisation d'une suite de Van der Corput a permis de stabiliser les estimateurs de manière significative par rapport à un Monte Carlo standard.

4.3 Variation

Objectif

Pour chaque grecques, tracer un graphe avec en abscisse le spot (ou la volatilité) et en ordonnée la dérivée partielle calculée. Vous interpréterez les résultats.

Le code de génération des graphiques est donné dans le code **Voir le code 4.3**

Toujours en gardant les même paramètres de l'exercice 4, on peut émettre les observations et vérifications suivantes :

Pour le Δ :

— Pour un Put, le Delta est toujours compris entre -1 et 0.

— Lorsque le prix du sous-jacent est faible ($S < K$), l'option est "in the money" et le Delta tend vers -1, signifiant que le prix du Put augmente presque autant que la baisse du spot.

— A mesure que S augmente au-delà du prix du strike ($K = 0.8$), l'option devient "out of the money" et le Delta tend vers 0, car la probabilité d'exercice diminue.

.

Pour le Γ :

— Le Gamma mesure la sensibilité du Delta par rapport au prix du sous-jacent

— Le graphique a une forme en cloche centrée autour du strike ($K = 0.8$). C'est à ce niveau ("At The Money") que l'incertitude est maximale et que le Delta change le plus rapidement.

.

Pour le $Vega$ par rapport au Spot :

— Le Vega représente la sensibilité du prix de l'option à la volatilité

— Il est maximal lorsque l'option est proche du strike. Cela montre que les options à la monnaie sont les plus sensibles aux changements de volatilité du marché

.

Pour le $Vega$ par rapport au sigma :

— Le graphique montre que pour une option de maturité longue ($T = 4$ par rapport à $T = 1$ dans l'exercice 1), la sensibilité à la volatilité reste positive et significative sur une large plage de valeurs de σ.

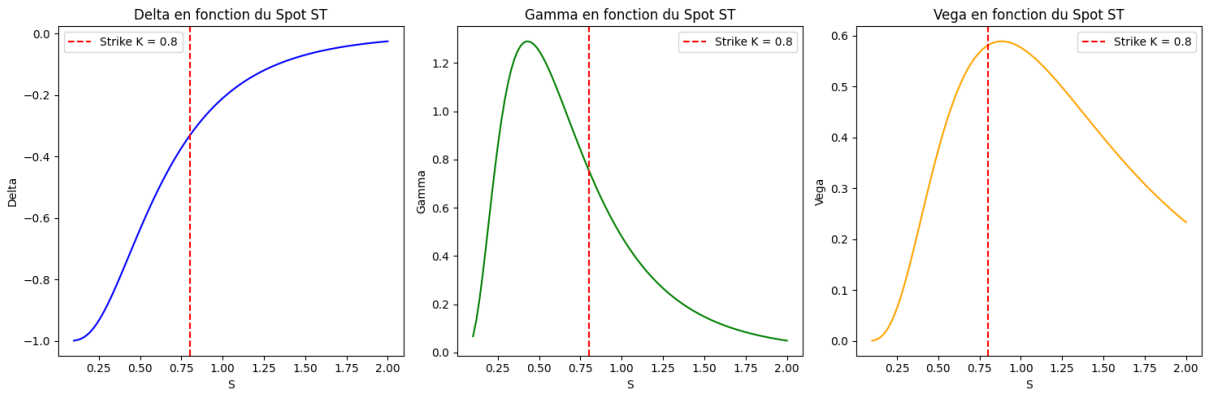

FIGURE 22 – Delta, Gamma et Vega en fonction du spot

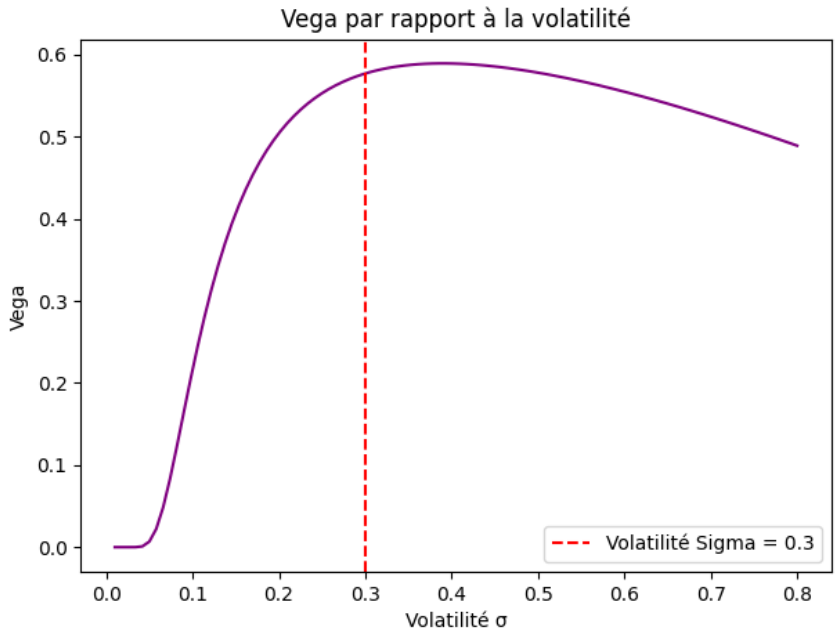

FIGURE 23 – Vega en fonction de la volatilité

4.4 Réduction de variance : Importance sampling

Objectif

En utilisant un changement de probabilité de votre choix et les trois méthodes de calculs vues précédemment, évaluer un put de strike 0.4.

Pour le 4.4, on fera d'abord une brève description de l'algorithme IS, puis un calcul de ses paramètres, la conséquence sur les 3 méthodes précédentes, puis les résultats.

Problème : dans une simulation de Monte Carlo classique, on doit tirer des variables aléatoires selon la loi normale standard $\mathcal{N}(0,1)$, sauf que avec $S_0 = 1$ et $K = 0.4$, l'option est très "Out of the Money" et donc la probabilité que la simulation tombe en dessous de 0.4 est extrêmement faible. Et donc la probabilité d'avoir un payoff non-nul est extrêmement faible, ce qui donne une variance (donc une instabilité) énorme dès que le payoff est non nul.

La solution est de faire que les simulation tombent autour du Strike $K = 0.4$, ce qui passe par un changement de probabilité. Dans notre cas, on doit faire un shift μ. On tire alors $\mathcal{N}(\mu, 1)$ avec μ choisit de manière à ce que l'espérance sous la nouvelle probabilité soit égale au strike.

Une fois le problème expliqué et la solution données, on doit faire le choix du shift μ et du poids L.

Nous choisissons μ de telle sorte que l'espérance du prix final sous la nouvelle probabilité $\mathbb{Q}'$ (qui est donc une probabilité équivalente) soit égale au strike : $\mathbb{E}^{\mathbb{Q}'}[S_T] = K$. Sous

$\mathbb{Q}'$, on a $Z = \tilde{Z} + \mu$ avec $\tilde{Z} \sim \mathcal{N}(0,1)$. Le prix du sous-jacent s'écrit :

$$S_T = S_0 \exp\left((r - \frac{\sigma^2}{2})T + \sigma\sqrt{T}(\tilde{Z} + \mu)\right)$$

En prenant l'espérance $\mathbb{E}^{\mathbb{Q}'}[S_T] = S_0 e^{rT+\sigma\sqrt{T}\mu}$, la condition $\mathbb{E}^{\mathbb{Q}'}[S_T] = K$ donne :

$$\mu = \frac{\ln(K/S_0) - rT}{\sigma\sqrt{T}}$$

Pour compenser ce changement de loi, chaque tirage est pondéré, comme le suggère le cours, par le facteur L :

$$L = \frac{\phi(Z)}{\phi(Z-\mu)} = \exp\left(-\mu Z + \frac{\mu^2}{2}\right)$$

Enfin, on effectue les changement du shift et de la pondération dans chacune des méthode précédentes, puis on s'intéresse au résultats.

L'importance sampling est intégré aux estimateurs des Grecques de la manière suivante :

1. **Différences Finies** : On calcule les prix $P(S_0 + h)$ et $P(S_0 - h)$ en utilisant les mêmes trajectoires "shiftées" et on multiplie le résultat par le poids L.
2. **Pathwise** : L'estimateur de la dérivée de la trajectoire est calculé sur les chemins shiftés, puis pondéré : $\Delta_{PW} = \mathbb{E}^{\mathbb{Q}'}[\frac{\partial f(S_T)}{\partial S_0} L]$.
3. **Likelihood Ratio** : On utilise l'estimateur classique calculé sur la variable originale, multiplié par le poids L pour rester sous la mesure $\mathbb{Q}'$.

Pour les résultats, l'application de l'importance sampling avec un décalage moyen $\mu \approx -1.66$ permet d'obtenir une bonne précision pour une option très Out of the Money ($K = 0.4$), là où un Monte Carlo classique fait clairement de moins bon scores. On prend, pour comparer, les méthodes les plus efficaces dans les 3 Greeks (Δ et $Vega$ avec PathWise et Γ avec Likelihood)

Grecque	**Méthode**	**Valeur IS**	**Valeur BS**	**Erreur Absolue**
Delta (Δ)	Pathwise	-0,024968	-0,024970	$2,05 \times 10^{-6}$
Vega	Pathwise	0,116763	0,116771	$7,90 \times 10^{-6}$
Gamma (Γ)	Likelihood	0,097312	0,097309	$3,27 \times 10^{-6}$

TABLE 3 – Comparaison des Grecques calculées par Importance Sampling ($K = 0.4$)

On observe que l'erreur est inférieure à 0.0001% ou d'ordre 10^{-6} pour les grecque. Pour comparer, sans l'IS, d'après le tableau calculé en 4.2, l'erreur tourne plutot autour de 10^{-4} voire au mieux 10^{-5}. L'IS transforme un événement rare en un événement fréquent, stabilisant donc les estimateurs. On remarque enfin que la méthode du Likelihood pour le Gamma, bien que plus bruitée, atteint ici une précision comparable aux méthodes Pathwise grâce au changement de probabilité.

5 Exercice 5 : volatilité stochastique et sauts

Le modèle de Bates fourni la dynamique suivante pour les actifs :

$$\frac{dS_t}{S_{t^-}} = (r - \lambda[\mu_a - 1])\,dt + \sqrt{v_{t^-}}\,dW_t^1 + dJ_t \tag{5}$$

$$dv_t = \kappa(\theta - v_t)dt + \xi\sqrt{v_t}dW_t^2 \tag{6}$$

$$J_T = \sum_{i=1}^{N_T}(A_i - 1) = \sum_{i=1}^{N_T}(e^{\mu_z + \sigma_z Z_i} - 1), \quad \mu_A = e^{\mu_z + \frac{\sigma_z^2}{2}}, \quad N_T \sim \text{Poisson}(\lambda T) \tag{7}$$

Comme nous avons pu le voir, le schéma d'Euler appliqué à la variance provoque des valeurs négative. Nous utiliserons les trois schémas afin d'empêcher ce phénomène :

- Absorbant en zéro : $\max(v_t, 0)$
- Reflexif en zéro : $|v_t|$
- Le schéma alternatifs proposé dans l'article de Leif Andersen : **Efficient Simulation of the Heston Stochastic Volatility Model**, "Quadratic exponential" : Page 13 - Page 17 résumé en 3.2.4

Les paramètres numériques seront les suivants :

$$S_0 = 1, \quad r = 0.02, \quad \lambda = 4, \quad \mu_z = 0.1, \quad \sigma_z = 0.3$$
$$v_0 = 0.05, \quad \kappa = 0.03, \quad \theta = 0.07, \quad \xi = 0.25, \quad \rho = -0.5$$

5.1 Diffusion du sous-jacent

Objectif

Appliquer chacun de ces schémas afin de vérifier que le sous jacent actualisé soit bien une martingale ($T = 5$).

$$\mathbb{E}[e^{-\int_0^T r ds} S_T | \mathcal{F}_0] = S_0$$

Dans le modèle de Bates, la variance suit un processus de type :

$$dv_t = \kappa(\theta - v_t)dt + \xi\sqrt{v_t}dW_t^2$$

Lorsqu'on applique un schéma d'Euler classique, il peut apparaître des valeurs négatives de variance. Ce phénomène est purement numérique et n'a pas de sens financier. Il est donc nécessaire d'utiliser des schémas correctifs pour remettre artificiellement la variance sur une valeur positive :

- Le schéma **absorbant** : $v_t = \max(v_t, 0)$
- Le schéma **réflexif** : $v_t = |v_t|$
- Le schéma **Quadratic Exponentiel** qui est basé sur l'approximation de la distribution conditionnelle exacte.

— Le schéma **Truncated Gaussian** qui est basé sur approximation gaussienne de la distribution conditionnelle, tronquée pour imposer la positivité

Pour valider si la propriété de martingale est bien vérifiée, on regarde numériquement si :

$$E[e^{-rT}S_T] = S_0$$

On vérifie donc numériquement que le sous-jacent actualisé reste une martingale. Les valeurs suivantes correspondent donc à l'estimation Monte Carlo de :

$$E[e^{-rT}S_T]$$

Et cette estimation doit être proche de $S_0 = 1$

On a aussi dans le tableau l'erreur relative en valeur absolue ainsi que la fréquence où chaque méthode donne l'erreur la plus faible.

Schéma	**Prix**	**Erreur Multiplicative**	**Fréquence Optimale**
Absorbant	1.0341371973849294	0.03356745334314676	0.0047
Réflexif	1.0341371973849294	0.03356745334314676	0.0
QE	1.0467098606556238	0.045651778542861655	0.9905
TG	1.0340726435952063	0.03350502854614125	0.0048

Table 4 – Comparaison des performances des schémas de discrétisation

Etant donné que réflexif et absorbant n'ont pas étais en dessous de 0 le schema ne s'est pas appliqué ce qui explique les mêmes valeurs, donc la valeur 0.1169 correspond à absorbant + réflexif.

On remarque donc que tous les schémas convergent vers la propriété de martingale et que le schéma QE présente l'erreur la plus faible. Il est donc le plus performant en moyenne, bien que cette conclusion soit assez précipité car ce schéma représente à pein plus de la moitié de la fréquence. Cependant, on peut dire avec moins de risque que le schéma réflexif semble être le moins efficace.

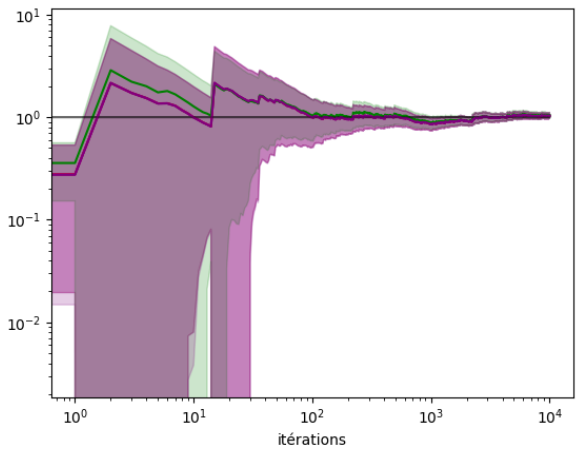

FIGURE 24 – Convergence des différents schéma vers S_0

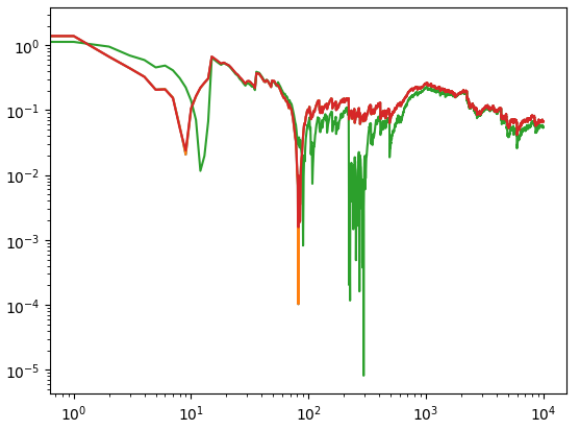

FIGURE 25 – Convergence des erreurs multiplicative en valeur absolue des different schéma

Voir le code 5.1

5.2 Pricing de Put

Appliquer chacun de ces schémas pour évaluer le prix du Put ($K = 1.05$)

Directement

Evaluer le prix du put Européen dans le modèle de Bates :

$$\mathbb{E}^{\mathbb{Q}}\left[e^{-\int_0^T rds}(K - S_T)_+ | \mathcal{F}_0\right]$$

On simule directement les trajectoires du sous-jacent sous la mesure risque neutre en utilisant les trois schémas de simulation de la variance.

Les résultats obtenus sont :

Schéma	Prix du Put
Absorbant	0.5420113798920608
Réflexif	0.5420113798920608
QE	0.5388352675254977
TG	0.5426370363870159

Les trois méthodes donnent des résultats proches, c'est rassurant.

Réduction de variance par conditionnement

En vous inspirant de l'application dans le modèle de Merton vu lors du cours, utilisez le conditionnement afin de réduire la variance de notre estimateur.

On conditionne sur la trajectoire de la variance et des sauts, puis on utilise la formule de Black-Scholes conditionnelle. Avec cela, on peut réduire fortement le bruit de Monte Carlo.

Résultat numérique :

$$\text{Moyenne (par conditionement)} = 0.5184563462763825 \tag{8}$$
$$\text{Ecart-type (par conditionement)} = 0.10655845226319072 \tag{9}$$

Le conditionnement permet une réduction importante de la variance de l'estimateur.

Réduction de variance par variable de contrôle

Utiliser le put dans le modèle de Black Scholes. Identifier le S_0 et la volatilité.

$$\beta\left(\mathbb{E}[e^{-rT}(K-S_T)_+|\mathcal{F}_0] - Put_{BS}(S,K,r,\sigma,T)\right)$$

On utilise le Put Black-Scholes comme variable de contrôle. Le coefficient optimal est estimé par :

$$\beta = \frac{Cov(X,Y)}{Var(Y)}$$

Pour réduire le biais de la variable de controle on a annulé le biais
On obtient la moyenne et l'écart type :

$$\text{Moyenne (avec variable de contrôle)} = 0.5426212709306618 \tag{10}$$
$$\text{Ecart-type (avec variable de contrôle)} = 0.34336407646291095 \tag{11}$$

On peut en conclure que la variable de contrôle réduit significativement la variance tout en conservant la moyenne estimée du prix.

Un fois qu'on a pu faire les calculs, ils faut faire une comparaison globale, pas seulement à la méthode direct mais aussi entre elles. On a donc les résultats suivant des comparaisons

Si on regroupe nos résultats, on a alors :

Méthode	Écart-type
Simulation brute	0.3487282582127816
Variable de contrôle Black-Scholes	0.34336407646291095
Conditionnement	0.10655845226319072

Table 5 – Comparaison des variances des estimateurs

On observe que le conditionnement est la méthode la plus efficace en termes de réduction de variance.
Enfin, les moyennes estimées sont résumées ci-dessous.

Méthode	Moyenne estimée
Simulation brute	0.5426036962687034
Variable de contrôle	0.5426212709306618
Conditionnement	0.5184563462763697

TABLE 6 – Comparaison des moyennes estimées

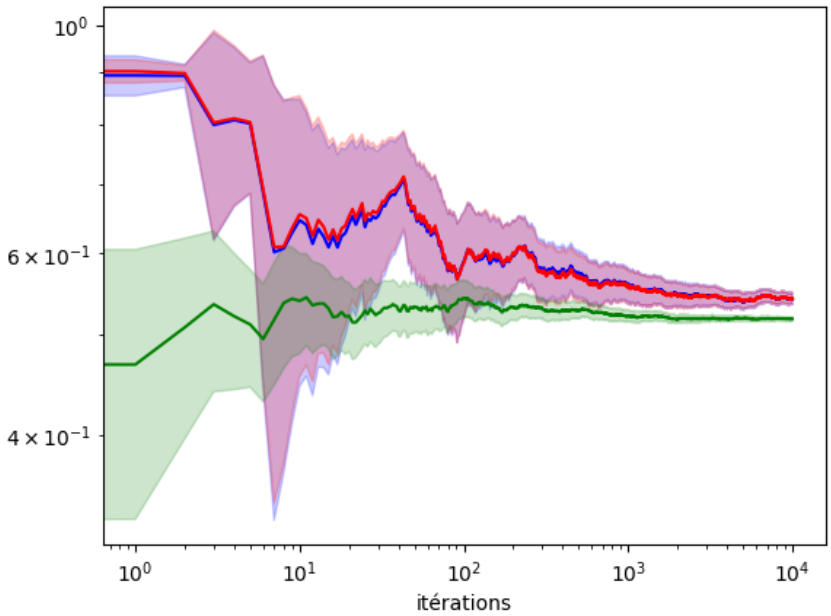

FIGURE 26 – convergence des prix des put par differente methode de réduction de variance

Voir le code 5.2

5.3 Variations et significativités

Objectif

Faites varier les paramètres $v_0, \kappa, \theta, \xi, \rho, \lambda, \mu_z$ et σ_z, interprétez vos résultats financière et qualitativement.

D'après les graphes obtenus numériquement, (**Voir le code 5.3**) on observe les comportements suivants :

Influence de v_0 : Comme v_0 correspond à la variance initiale, il est naturel que le prix du Put augmente lorsque v_0 augmente. En effet, une variance initiale élevée implique que le sous-jacent commence avec une forte incertitude. La variance ne converge pas instantanément vers la variance de long terme θ, ce qui augmente la dispersion des trajectoires du sous-jacent et donc la valeur de l'option.

Influence de λ : Le paramètre λ correspond à l'intensité du processus de Poisson, c'est-à-dire à la fréquence des sauts. Une augmentation de λ augmente la probabilité d'observer des sauts, ce qui augmente la variance totale du sous-jacent. Il est donc logique que le

prix du Put augmente avec λ. La forme concave observée suggère un effet de saturation : au-delà d'un certain niveau, ajouter des sauts supplémentaires augmente moins fortement le risque marginal.

Influence de μ_z : Le paramètre μ_z correspond à la moyenne de la taille logarithmique des sauts. Numériquement, on observe que lorsque la taille moyenne des sauts augmente en valeur absolue, le prix du Put augmente également. Cela peut s'expliquer par le fait que des sauts plus importants, qu'ils soient positifs ou négatifs, augmentent la volatilité effective du sous-jacent. On pourrait s'attendre théoriquement à ce que des sauts majoritairement positifs réduisent le prix du Put. Cependant, l'augmentation de la volatilité due à l'augmentation de la taille des sauts peut être une des explications.

Influence de σ_z : Le paramètre σ_z correspond à la variance de la taille des sauts. Une augmentation de σ_z augmente l'incertitude sur l'amplitude des sauts, ce qui augmente la variance globale du sous-jacent et donc le prix de l'option.

Influence de κ : Le paramètre κ correspond à la vitesse de retour vers la moyenne θ. Une augmentation de κ force la variance à revenir plus rapidement vers sa moyenne de long terme. Selon la position relative de v_0 et θ, cela peut augmenter ou diminuer la variance moyenne observée sur l'intervalle de temps, s'il est trop grand cela peux oscillé ce qui pourrais explique un effet potentiellement croissant sur le prix du Put.

Influence de θ : Le paramètre θ correspond à la variance de long terme. Une augmentation de θ augmente la variance moyenne du processus, ce qui augmente naturellement le prix du Put.

Influence de ξ : Le paramètre ξ correspond à la volatilité de la variance (vol-of-vol). Théoriquement d'un point de vue financier, une augmentation de ξ devrait augmenter l'incertitude sur la variance future et donc augmenter le prix de l'option. Si un comportement décroissant est observé numériquement, cela peut provenir soit d'effets numériques, d'interactions avec les autres paramètres, d'un nombre de simulations insuffisant soit d'un du a la nature mathématique de ce processus.

Influence de ρ : Le paramètre ρ correspond à la corrélation entre le mouvement du sous-jacent et celui de la variance. Lorsque ρ est fortement négatif, une augmentation de la variance tend à être compensée par un mouvement opposé du sous-jacent, ce qui réduit la volatilité effective. Ainsi, lorsque ρ augmente (devient moins négatif), cette compensation diminue, ce qui augmente la volatilité effective et donc le prix du Put.

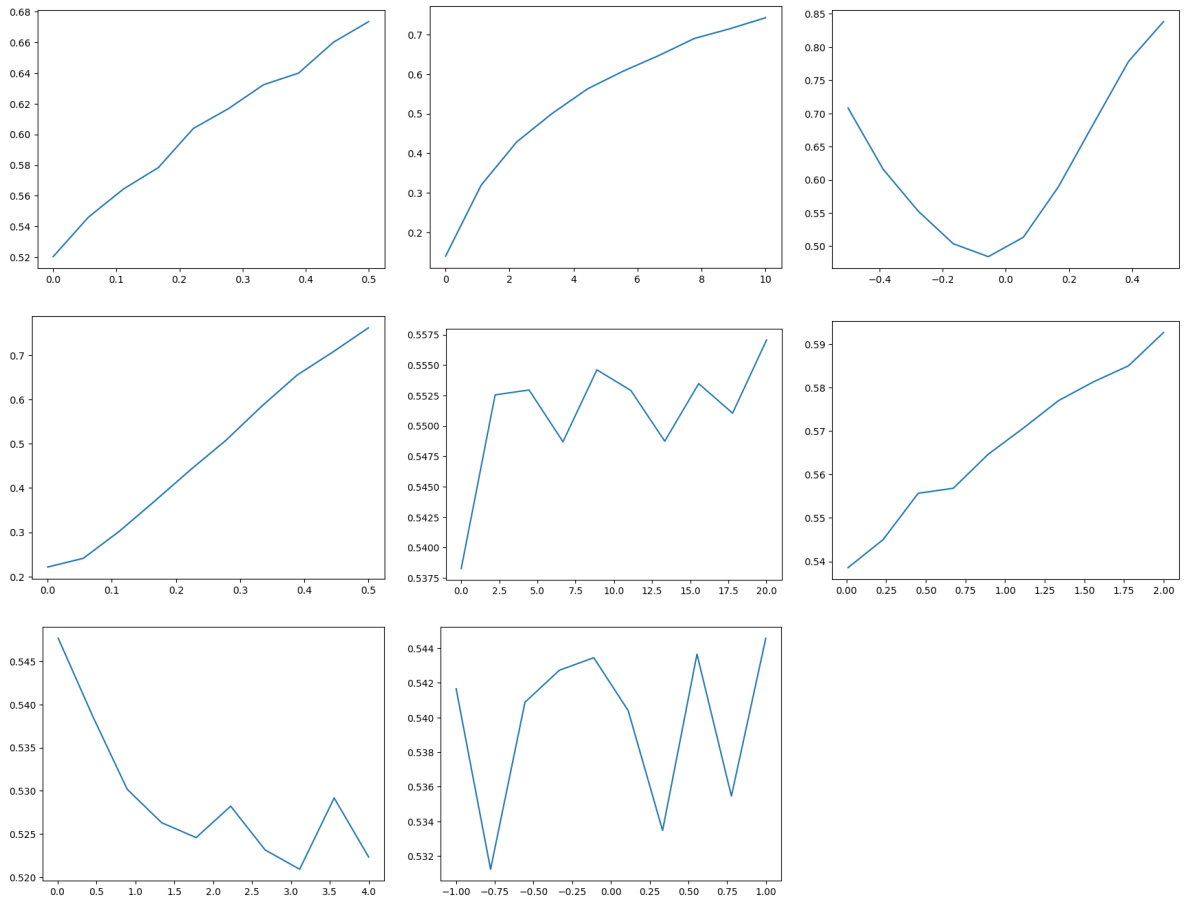

FIGURE 27 – Evolution, dans l'ordre, de : v_0, λ, μ_z, σ_z, κ, θ, ξ, ρ

5.4 Réduction du biais

Objectif

Utiliser la méthodes de Romberg Richadson de niveau 2 afin de réduire le biais de votre estimateur

La méthode de Richardson–Romberg est une technique de réduction du biais des estimateurs numériques. Elle repose sur l'idée que si un estimateur possède un biais d'ordre $O(h)$ (avec h le pas de discrétisation), il est possible de combiner deux estimateurs obtenus avec deux pas différents afin d'annuler le terme dominant du biais.

Dans notre cas, on utilise deux estimations du prix obtenues avec deux niveaux de discrétisation (P_N, estimation obtenue avec N pas de temps et P_{2N}, estimation obtenue avec $2N$ pas de temps)

On a alors un estimateur corrigé du biais :

$$P_{RR} = 2P_{2N} - P_N$$

Cet estimateur permet théoriquement d'obtenir un biais d'ordre supérieur tout en conservant une variance proche de celle de l'estimateur le plus précis.

Les résultats numériques obtenus sont résumés dans le tableau suivant :

Estimateur	Valeur
P_N	0.5200702797943763
P_{2N}	0.5199049900920149
P_{RR}	0.5197397003896534

Table 7 – Correction de biais par méthode de Richardson–Romberg

Nous n'avons pas de points de comparaison fiable pour savoir si la méthode fonctionne ou non.

Références

[1] KTH Royal Institute of Technology. *Local Volatility and the Dupire Equation*. Mathematical Statistics, Project in Financial Mathematics, 2016. Disponible en ligne : https://www.math.kth.se/matstat/gru/5b1575/Projects2016/VolatilitySurface.pdf

[2] LexiFi. *Jump-diffusion models : Merton and Bates*. LexiFi Blog, Quant Section. Disponible en ligne : https://www.lexifi.com/blog/quant/jump-diffusion-models-merton-and-bates/

[3] Xbeat (GitHub). *Dynamic Price Modeling with Bates Model in Python*. Machine Learning Repository, 2024. Disponible en ligne : https://github.com/xbeat/Machine-Learning/blob/main/Dynamic%20Price%20Modeling%20with%20Bates%20Model%20in%20Python.md